

Nombre:

CI:

P1	P2	P3

CLAVE Quiz 2

1. Considere el SEL $Ax = b$, con A no singular, $b \in \mathbb{R}^n$ no nulo. Se sabe que si δb y δx son las perturbaciones en los vectores b y x , entonces se cumple que

$$\frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|},$$

donde $\text{cond}(A)$ denota el número de condición de A . En el caso que $\frac{\|\delta b\|}{\|b\|} \leq 10^{-d}$ con $d > 0$; ¿bajo cuáles condiciones se considera A mal condicionada? **(6 pts)**

Solución

El mal condicionamiento de A depende de la precisión que se tenga en la data de entrada (vector b) y de la precisión que se quiera en la data de salida (vector x). Por ejemplo, si se tiene que $\frac{\|\delta b\|}{\|b\|} \leq 10^{-d}$ con $d > 0$, entonces de la cota dada en el enunciado se desprende que

$$\frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|} \leq \text{cond}(A) 10^{-d} \quad (1)$$

Ahora bien, si quiere que $\frac{\|\delta x\|}{\|x\|} \leq 10^{-p}$ con $p \geq 0$ entonces basta con garantizar que el lado derecho de (1) sea menor o igual a 10^{-p} , es decir

$$\text{cond}(A) 10^{-d} \leq 10^{-p} \iff \text{cond}(A) \leq 10^{d-p}$$

Note que, de esta última desigualdad se pueden concluir dos cosas

- (a) Si $\text{cond}(A) \in [1, 10^{d-p}]$ se considera que A está bien condicionada; pero si $\text{cond}(A) \in (10^{d-p}, \infty)$ se considera que A está mal condicionada.
- (b) Al observar la cota obtenida para $\text{cond}(A)$ queda claro que la misma depende de d (valor asociado a la data de entrada) y de p (valor asociado a la data de salida).

2. El método de mínimo descenso para resolver $Ax = b$ con A SPD, se define como:

$$x_{k+1} = x_k + t_k r_k$$

donde $r_k = b - Ax_k$, $t_k = \frac{\langle r_k, r_k \rangle}{\langle r_k, Ar_k \rangle}$ y x_0 es dado. Demuestre que en cada iteración $k \geq 0$ de mínimo descenso se cumple que:

$$r_{k+1} \perp r_k.$$

(7 pts)

Solución

Sea $k \geq 0$ la iteración actual de mínimo descenso, sabemos que:

$$r_{k+1} = b - Ax_{k+1} = b - A(x_k + t_k r_k) = b - Ax_k - t_k Ar_k = r_k - t_k Ar_k \quad (2)$$

Y sustituyendo (2) en $\langle r_{k+1}, r_k \rangle$, aplicando algunas propiedades de la función de producto interno y usando la definición de t_k , se tiene lo siguiente:

$$\begin{aligned} \langle r_{k+1}, r_k \rangle &= \langle r_k - t_k Ar_k, r_k \rangle = \langle r_k, r_k \rangle - t_k \langle Ar_k, r_k \rangle \\ &= \langle r_k, r_k \rangle - \frac{\langle r_k, r_k \rangle}{\langle r_k, Ar_k \rangle} \langle r_k, Ar_k \rangle = \langle r_k, r_k \rangle - \langle r_k, r_k \rangle \\ &= 0 \end{aligned}$$

Es decir, dos residuales consecutivos del método del mínimo descenso son ortogonales (i.e. $r_{k+1} \perp r_k$).

3. ¿Cuál es el escalar α que minimiza $\|y - \alpha x\|_2$ donde $x, y \in \mathbb{R}^n$ son vectores dados?.
- (7 pts)

Solución

De clases se sabe que, dada $A \in \mathbb{R}^{n \times m}$ con $n \geq m$ de rango completo ($R(A) = m$); el LSP se define como

$$\text{Hallar } x \in \mathbb{R}^m \text{ (no nulo) tal que minimice } \|b - Ax\|_2 \quad (3)$$

Más aún, se sabe que la solución de (3) es equivalente a resolver el SEL de las ecuaciones normales (EN):

$$A^T Ax = A^T b \quad (4)$$

Note que, minimizar $\|y - \alpha x\|_2$, es un LSP con $m = 1$, cuya solución puede hallarse resolviendo las EN asociadas:

$$x^T x \alpha = x^T y \iff \alpha = \frac{x^T y}{x^T x}$$

Detalles: SI se toma $m = 1$, y se redefinen $x := \alpha$ (α es la incógnita) $b := y$ (y el vector independiente) y $A := x$ (x será la *matriz* de coeficientes); **ENTONCES** el LSP dado en (3) se reescribe como

$$\text{Hallar } \alpha \in \mathbb{R}^m \text{ (no nulo) tal que minimice } \|y - x\alpha\|_2$$

y sus EN asociadas son $A^T Ax = A^T b := x^T x \alpha = x^T y \iff \alpha = \frac{x^T y}{x^T x}$. Note que x NO PUEDE SER el vector nulo (*¿Por qué?*).

CLAVE
Parcial II

1. Considere el SEL $Ax = b$, con A no singular, $b \in \mathbb{R}^n$ no nulo.

- (a) Si δb y δx son perturbaciones en los vectores b y x respectivamente tales que $\hat{b} = b + \delta b$ y $\hat{x} = x + \delta x$, demuestre que

$$\frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|},$$

donde $\text{cond}(A) = \|A\| \|A^{-1}\|$ denota el número de condición de A . **(5 pts)**

- (b) Suponiendo que $\text{cond}(A) \leq 10^m$ con $m \geq 0$; de una cota para el error relativo de $\hat{b}$ (data de entrada) si se quiere que la solución aproximada $\hat{x}$ (data de salida) tenga un error relativo por debajo de 10^{-t} , con $t > 0$. **(2 pts)**

Solución

(a) $\delta x = \hat{x} - x = A^{-1}\hat{b} - A^{-1}b = A^{-1}(\hat{b} - b) \Rightarrow \|\delta x\| = \|A^{-1} \delta b\|$

$$\begin{aligned} \|\delta x\| &\leq \|A^{-1}\| \|\delta b\| = \frac{\|A^{-1}\| \|\delta b\| \|b\|}{\|b\|} = \frac{\|A^{-1}\| \|\delta b\| \|Ax\|}{\|b\|} \\ &\leq \frac{\|A^{-1}\| \|\delta b\| \|A\| \|x\|}{\|b\|} \Rightarrow \\ \frac{\|\delta x\|}{\|x\|} &\leq \underbrace{\|A\| \|A^{-1}\|}_{\text{cond}(A)} \frac{\|\delta b\|}{\|b\|} \end{aligned}$$

(b) Similar a la realizado en el Quiz 2.

2. El método de gradientes conjugados para resolver $Ax = b$ con A SPD, se define como:

$$x_{k+1} = x_k + t_k u_k$$

donde $u_0, u_1, \dots, u_k$ son direcciones A -conjugadas, $t_k = \frac{\langle u_k, r_k \rangle}{\langle u_k, Au_k \rangle}$, $r_k = b - Ax_k$ y x_0 es dado. Demuestre que en cada iteración $k \geq 0$ de gradientes conjugados se cumple que:

(a) $r_{k+1} = r_k - t_k Au_k$ **(1 pto)**

(b) $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$ **(2 pto)**

(c) $t_k = \frac{\langle u_k, r_0 \rangle}{\langle u_k, Au_k \rangle}$ **(2 pts)**

(d) $r_{k+1} \perp r_j$, con $j = 0, 1, \dots, k$. **(4 pts)**

Ayuda ítem (d): Recuerde que $r_{k+1} \perp u_j$, con $j = 0, 1, \dots, k$

Solución

(a) $r_{k+1} = b - Ax_{k+1} = b - A(x_k + t_k u_k) = (b - Ax_k) - A(t_k u_k) = r_k - t_k A u_k$

(b) Sencillamente se debe aplicar de manera sucesiva la definición de x_{k+1} :

$$x_{k+1} = x_k + t_k u_k = (x_{k-1} + t_{k-1} u_{k-1}) + t_k u_k = \dots = x_0 + t_1 u_1 + \dots + t_{k-1} u_{k-1} + t_k u_k$$

y por tanto $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$

(c) Tomando la definición de x_k obtenida del ítem anterior; multiplicándola a ambos lados por $-A$ y sumado b se obtiene que

$$b - Ax_k = b - Ax_0 + \sum_{j=0}^{k-1} t_j u_j \Rightarrow r_k = r_0 - \sum_{j=0}^{k-1} t_j A u_j$$

Sustituyendo esta última expresión de r_k en la definición de t_k y aplicando propiedades del producto interno se tiene que

$$\begin{aligned} t_k &= \frac{\langle u_k, r_k \rangle}{\langle u_k, A u_k \rangle} = \frac{\langle u_k, r_0 - \sum_{j=0}^{k-1} t_j A u_j \rangle}{\langle u_k, A u_k \rangle} = \frac{\langle u_k, r_0 \rangle - \langle u_k, \sum_{j=0}^{k-1} t_j A u_j \rangle}{\langle u_k, A u_k \rangle} \\ &= \frac{\langle u_k, r_0 \rangle - \sum_{j=0}^{k-1} \langle u_k, t_j A u_j \rangle}{\langle u_k, A u_k \rangle} = \frac{\langle u_k, r_0 \rangle - \sum_{j=0}^{k-1} t_j \langle u_k, A u_j \rangle}{\langle u_k, A u_k \rangle} \end{aligned}$$

y en vista que $j < k$, por la A -ortogonalidad de las direcciones u_j se tiene que $\langle u_k, A u_j \rangle = 0$; y esta prueba lo solicitado.

(d) Las direcciones u_k se obtienen aplicando el proceso de Gram-Schmidt a las residuales $r_k = b - Ax_k$ (generados por mínimo descenso). Por tanto los r_k y los u_k **generan el mismo espacio**, es decir, $\text{span}(\{r_0, r_1, \dots, r_k\}) = \text{span}(\{u_0, u_1, \dots, u_k\})$ de donde se desprende que deben existir escalares α 's no todos ceros, tales que

$$r_j = \alpha_0 u_0 + \alpha_1 u_1 + \dots + \alpha_k u_k = \sum_{j=0}^k \alpha_j u_j,$$

para $j = 0, 1, \dots, k$. Ahora bien, sustituyendo esta última expresión en $\langle r_{k+1}, r_j \rangle$ y aplicando propiedades del producto interno, se tiene que

$$\langle r_{k+1}, r_j \rangle = \langle r_{k+1}, \sum_{j=0}^k \alpha_j u_j \rangle = \sum_{j=0}^k \langle r_{k+1}, \alpha_j u_j \rangle = \sum_{j=0}^k \alpha_j \langle r_{k+1}, u_j \rangle$$

finalmente, dado que $r_{k+1} \perp u_j$, para $j = 0, 1, \dots, k$, es decir, $\langle r_{k+1}, u_j \rangle = 0$ se concluye lo solicitado.

3. Sean $\{(x_i, y_i)\}$ $i = 1, \dots, n$ un conjunto de datos. Demuestre que la función constante $y = C$ que mejor aproxima a ese conjunto de puntos, en el sentido de los mínimos

cuadrados, viene dada por:

$$y = \frac{1}{n} \sum_{i=1}^n y_i.$$

(4 pts)

Solución

GENTE ESTA ES LA MISMA PREGUNTA DEL QUIZ, pero formulada de manera diferente; QUE ADEMAS FUE UNA PREGUNTA TOMADA DE LA PRÁCTICA O.o

El modelo de ajuste es $y = C$, por lo tanto se busca que en cada medición se cumplan las siguientes n condiciones (una por cada medición)

$$\begin{aligned} C &= y_1 \\ C &= y_2 \\ &\vdots \\ C &= y_n \end{aligned},$$

que es obviamente un SEL sobredeterminado con UNA sola incógnita (C). Este SEL se escribe matricialmente como

$$\underbrace{\begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}}_x \underbrace{\begin{matrix} A \\ C \\ \alpha \end{matrix}}_x = \underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}}_y \underbrace{\begin{matrix} b \end{matrix}}_y$$

y se resuelve mediante el LSP que **minimiza $\|y - x\alpha\|_2$ (problema del quiz)**, cuya solución se obtiene mediante las EN

$$A^T A x = A^T b := x^T x C = x^T y \iff C = \frac{x^T y}{x^T x}.$$

Para este problema de ajuste se tiene que $x^T y = \sum_{i=1}^n y_i$ y $x^T x = \sum_{i=1}^n 1 = n$, y por tanto se concluye que $C = \frac{1}{n} \sum_{i=1}^n y_i$