

Cálculo Científico: Resumen Completo para el Parcial 2

Temas 3 y 4: Factorizaciones Matriciales y Sistemas Lineales Numéricos

Luisdavid Colina — 24.766.381

UCV, Escuela de Computación, I-2026

1. Matrices Ortogonales y Householder

1.1. Matrices ortogonales

$Q \in \mathbb{R}^{n \times n}$ es ortogonal si $Q^T Q = Q Q^T = I$, i.e., $Q^{-1} = Q^T$.

Propiedades: $\|Qx\|_2 = \|x\|_2$ (preserva norma); $\det(Q) = \pm 1$; $Q_1 Q_2$ es ortogonal.

Resultado Clave

Prueba: producto de ortogonales es ortogonal (telescópico).

$$(Q_1 \cdots Q_n)^T (Q_1 \cdots Q_n) = Q_n^T \cdots \underbrace{Q_1^T Q_1}_{=I} \cdots Q_n = \cdots = Q_n^T Q_n = I. \quad \square$$

1.2. Matrices de Householder

$$H = I - \frac{2}{v^T v} v v^T = I - 2\rho v v^T, \quad \rho = \frac{1}{v^T v}, \quad v \neq 0.$$

Resultado Clave

9 propiedades con demostración:

P1. **Simétrica:** $(v v^T)^T = v v^T$ y ρ es escalar, luego $H^T = H$.

P2. **Ortogonal** ($H^2 = I$): $(I - 2\rho v v^T)^2 = I - 4\rho v v^T + 4\rho^2 v \underbrace{(v^T v)}_{1/\rho} v^T = I$.

P3. **Involutoria** ($H^{-1} = H$): de $H^2 = I$, multiplicar $H^{-1} H^2 = H^{-1} \Rightarrow H = H^{-1}$.

P4. $\det(H) = -1$: lema matricial $\det(I - 2\rho v v^T) = 1 - 2\rho v^T v = 1 - 2 = -1$.

P5. $Hv = -v$: $Hv = v - 2\rho(v^T v)v = v - 2v = -v$.

P6. $Hx = x$ si $x \perp v$: $Hx = x - 2\rho \underbrace{(v^T x)}_{=0} v = x$.

P7. **Autovalores:** -1 (mult. 1, autovect. v) y $+1$ (mult. $n - 1$, $v^\perp$).

P8. $\|Hx\| = \|x\|$: H es ortogonal, preserva norma.

P9. **Aniquilación:** construir $v = a + \operatorname{sgn}(a_1)\|a\|e_1 \Rightarrow Ha = -\operatorname{sgn}(a_1)\|a\|e_1$.

Por qué sumar (no restar) en P9. Si $a_1 > 0$ y restáramos: $v_1 = a_1 - \|a\| \approx 0$ (cancelación catastrófica). Sumando: $v_1 = a_1 + \|a\| > 0$ (estable).

Ejemplo numérico: $a = (1, 2, -2)^T$, $\|a\| = 3$, $\operatorname{sgn}(a_1) = +1$. $v = (4, 2, -2)^T$, $v^T v = 24$, $\rho = 1/12$. $H = I - \frac{1}{12} v v^T = \frac{1}{3} \begin{bmatrix} -1 & -2 & 2 \\ -2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix}$. $Ha = (-3, 0, 0)^T = -3e_1 = -\|a\|e_1$. ✓

2. Factorización LU

Forma: $A = LU$, L triangular inferior unitaria (1s en diagonal), U triangular superior.

Existencia sin pivoteo: $\Leftrightarrow$ todos los menores principales $M_k = \det(A_{1:k, 1:k}) \neq 0$.

[title=Eliminación Gaussiana: $A = LU$] Para $j = 1, \dots, n - 1$ (columna pivote):

1. Para $i = j + 1, \dots, n$: $\ell_{ij} = a_{ij}/a_{jj}$ (multiplicador; guarda en L)
2. Para $i = j + 1, \dots, n$: $A_{i,j:n} \leftarrow A_{i,j:n} - \ell_{ij} \cdot A_{j,j:n}$ (actualizar fila)

L = triangular inferior con los ℓ_{ij} y unos en diagonal; $U = A$ resultante.

Resolver $Ax = b$: $Ly = b$ (adelante $O(n^2)$), $Ux = y$ (atrás $O(n^2)$). Costo total $n^3/3 + 2n^2$.

Ejemplo 3×3 : $A = \begin{bmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{bmatrix}$. Col 1 (pivot=2): $\ell_{21} = 2$, $R_2 \rightarrow (0, 1, 1)$; $\ell_{31} = 4$, $R_3 \rightarrow (0, 3, 5)$. Col 2 (pivot=1): $\ell_{32} = 3$, $R_3 \rightarrow (0, 0, 2)$.

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix}. \quad LU = A. \checkmark$$

Pivoteo parcial $PA = LU$: intercambiar con el mayor pivote $\Rightarrow |\ell_{ij}| \leq 1$. Resolver: $Ly = Pb$ (adelante), $Ux = y$ (atrás).

Cuidado

No existe LU (sin pivoteo) si algún $M_k = 0$. Detectar: calcular $M_1, M_2, \dots$ hasta el primero nulo.

Tridiagonal: $\pi_1 = \beta_1$, $\pi_{k+1} = \beta_{k+1} - \alpha_k \gamma_k / \pi_k$. Costo $O(n)$.

Resultado Clave

Unicidad: de $L_1 U_1 = L_2 U_2 \Rightarrow L_2^{-1} L_1 = U_2 U_1^{-1}$. Izquierda: triangular inferior. Derecha: triangular superior. $\Rightarrow$ ambas diagonales. Los unos de L_i fuerzan $L_2^{-1} L_1 = I$, luego $L_1 = L_2$, $U_1 = U_2$. $\square$

3. Factorización de Cholesky

Hipótesis: A simétrica y definida positiva (SPD). $\exists! L$ triangular inferior con $\ell_{ii} > 0$: $A = LL^T$. Costo $\sim n^3/6$; no requiere pivoteo.

[title=Factorización de Cholesky: $A = LL^T$] Para $j = 1, \dots, n$ (columna):

1. $\ell_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} \ell_{jk}^2}$ (diagonal; falla si A no SPD)
2. Para $i = j + 1, \dots, n$: $\ell_{ij} = (a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} \ell_{jk}) / \ell_{jj}$

Resolver $Ax = b$: $Ly = b$ (adelante), $L^T x = y$ (atrás). Costo $n^3/6 + n^2$.

Ejemplo 2×2 : $A = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$. $\ell_{11} = 2$; $\ell_{21} = 1$; $\ell_{22} = \sqrt{3-1} = \sqrt{2}$. $L = \begin{bmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{bmatrix}$, $LL^T = A$. $\checkmark$

Test SPD: el algoritmo falla (raíz de negativo) $\Leftrightarrow A$ no es SPD.

Resultado Clave

Unicidad: sea $R = M^{-1}L$ (triangular inferior). De $A = LL^T = MM^T$: $RR^T = I$, i.e., R ortogonal + triangular inferior. Por inducción $r_{11}^2 = 1, r_{11} > 0 \Rightarrow r_{11} = 1$; el resto cae por inducción. Luego $R = I$, es decir $L = M$. $\square$

Por bloques. $B = \begin{bmatrix} A & a \\ a^T & \alpha \end{bmatrix}$ SPD, $A = LL^T$: $L_B = \begin{bmatrix} L & 0 \\ \ell^T & \beta \end{bmatrix}$ con $L\ell = a$ y $\beta = \sqrt{\alpha - \ell^T \ell}$.

4. Factorización QR

Forma: $A \in \mathbb{R}^{m \times n}$ ($m \geq n$) $\Rightarrow A = QR$, Q ortogonal, R triangular superior.

4.1. Gram-Schmidt

[title=QR por Gram-Schmidt (Clásico)] Para $j = 1, \dots, n$:

1. Para $i = 1, \dots, j-1$: $r_{ij} = \langle q_i, a_j \rangle$ (proyecciones)
2. $\hat{q}_j = a_j - \sum_{i < j} r_{ij} q_i$ (ortogonalizar)
3. $r_{jj} = \|\hat{q}_j\|$; $q_j = \hat{q}_j / r_{jj}$ (normalizar)

$Q = [q_1 | \dots | q_n]$, $R = (r_{ij})$ triangular superior. Costo: $\sim 2mn^2$.

G-S Modificado: en el paso 2, actualizar $a_j \leftarrow a_j - r_{ij} q_i$ uno a la vez (más estable).

$$\hat{q}_j = a_j - \sum_{i < j} \underbrace{\langle q_i, a_j \rangle}_{r_{ij}} q_i = (I - Q_{j-1} Q_{j-1}^T) a_j, \quad q_j = \hat{q}_j / \|\hat{q}_j\|, \quad r_{jj} = \|\hat{q}_j\|.$$

Ejemplo: $A = \begin{bmatrix} 1 & 3 \\ 1 & 4 \\ 1 & -4 \end{bmatrix}$. $q_1 = \frac{1}{2}(1, 1, 1)^T$, $r_{11} = 2$. $r_{12} = q_1^T a_2 = 0$ ($a_1 \perp a_2$, no hay proyección que restar). $q_2 = (3, -3, 4, -4)^T / (5\sqrt{2})$, $r_{22} = 5\sqrt{2}$. $R = \begin{bmatrix} 2 & 0 \\ 0 & 5\sqrt{2} \end{bmatrix}$.

Cuidado

Gram-Schmidt clásico pierde ortogonalidad en aritmética de pocos dígitos. La versión **Modificada** (actualiza proyecciones sobre la marcha) es más estable.

4.2. Householder

[title=QR por Householder] Para $k = 1, \dots, \min(m-1, n)$:

1. $a = A_{k:m,k}$ (subcolumna activa).
2. $v = a + \text{sgn}(a_1) \|a\| e_1$ (vector de Householder).
3. $\rho = 2/(v^T v)$.
4. $A_{k:m,k:n} \leftarrow A_{k:m,k:n} - \rho v (v^T A_{k:m,k:n})$ (aplicar H_k).

$R = H_p \dots H_1 A$, $Q = H_1 \dots H_p$.

Ejemplo: $A = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 3 & 1 \\ -2 & 0 & -1 \end{bmatrix}$.

Paso 1: $a = (1, 2, -2)^T$, $\|a\| = 3$; $v = (4, 2, -2)^T$, $\rho = 1/12$. $H_1 = \frac{1}{3} \begin{bmatrix} -1 & -2 & 2 \\ 2 & 1 & 2 \end{bmatrix}$, $A_1 = H_1 A = \begin{bmatrix} -3 & -3 & -3 \\ 0 & 0 & -3 \\ 0 & 3 & 3 \end{bmatrix}$.

Paso 2: subvec $(0, 3)^T$; $v = (3, 3)^T$, $H_2 = \text{diag}(1, \begin{bmatrix} 0 & -1 \\ -1 & 0 \end{bmatrix})$. $R = \begin{bmatrix} -3 & -3 & -3 \\ 0 & -3 & -3 \\ 0 & 0 & 3 \end{bmatrix}$, $Q = \frac{1}{3} \begin{bmatrix} -1 & -2 & 2 \\ -2 & -1 & -2 \\ 2 & -2 & -1 \end{bmatrix}$.
✓

Prop.: $\|A\|_F = \|R\|_F$ (transformaciones ortogonales preservan norma Frobenius).

QR $\leftrightarrow$ Cholesky: $A^T A = R^T R = L L^T \Rightarrow R = L^T$ (si diagonal de R positiva).

5. SVD — Descomposición en Valores Singulares

Toda $A \in \mathbb{R}^{m \times n}$: $A = U \Sigma V^T$, $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ ortogonales; Σ diagonal con $\sigma_1 \geq \dots \geq \sigma_r > 0$.

[title=Algoritmo SVD]

1. Formar $C = A^T A$ (simétrica, semidefinida positiva).
2. Calcular autovalores $\lambda_i \geq 0$ de C .
3. $\sigma_i = \sqrt{\lambda_i}$; armar Σ .
4. Autovectores ortonormales v_i de $C \Rightarrow$ armar V .
5. $u_i = A v_i / \sigma_i$ para $\sigma_i > 0$; completar a base ortonormal $\Rightarrow U$.
6. Verificar $A = U \Sigma V^T$.

Por qué u_i son ortonormales: $\langle u_i, u_j \rangle = \frac{v_i^T A^T A v_j}{\sigma_i \sigma_j} = \frac{\lambda_j v_i^T v_j}{\sigma_i \sigma_j} = \delta_{ij}$.

Resultado Clave

Propiedades útiles: $\text{rango}(A) = r$; $\|A\|_2 = \sigma_1$; $\|A\|_F^2 = \sum \sigma_i^2$; $\kappa_2(A) = \sigma_1 / \sigma_n$.

Control numérico: $\sum \lambda_i = \text{tr}(C) = \|A\|_F^2$ (verificar eigenvalores).

Mejor aprox. rango k : $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$.

6. Mínimos Cuadrados

Dado $Ax = b$ sobredeterminado ($m > n$): minimizar $\|b - Ax\|_2$.

Ecuaciones normales: $A^T A \hat{x} = A^T b$. Si cols. de A son LI: $\hat{x} = (A^T A)^{-1} A^T b$.

Resultado Clave

Prueba (residuo $\perp$ columnas): $f(x) = \|b - Ax\|^2$, $\nabla f = -2A^T(b - Ax) = 0 \Rightarrow A^T(b - A\hat{x}) = 0$, i.e., residuo $\perp$ cada columna de A .

$A^T A$ es SPD si cols. LI: $x^T(A^T A)x = \|Ax\|^2 \geq 0$; $= 0 \Leftrightarrow x = 0$ (con cols. LI). $\square$

Via QR (recomendado): $A = Q \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$, $Q^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$. Resolver $R_1 \hat{x} = c_1$. Residuo mínimo $= \|c_2\|$. *Ventaja:* $\kappa(R_1) = \kappa(A) \ll \kappa(A^T A) = \kappa(A)^2$.

Casos especiales:

- Escalar óptimo: $\hat{\alpha} = a^T b / (a^T a)$.
- Constante óptima: $\hat{C} = \frac{1}{n} \sum y_i$ (media).
- **Regresión lineal** $\hat{y} = a + bt$: con $A = [\mathbf{1}, \mathbf{t}]$, resolver $A^T A \begin{pmatrix} a \\ b \end{pmatrix} = A^T \mathbf{y}$.

Ejemplo de regresión: datos $(1, 7), (2, 4), (3, 3)$. $A^T A = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$, $A^T y = \begin{bmatrix} 14 \\ 24 \end{bmatrix}$. $\hat{b} = -2$, $\hat{a} = 26/3$. Modelo: $\hat{y} = 26/3 - 2t$. Pérdida cuando $\hat{y} = 0$: $t = 13/3$, es decir mes 4 del año 4.

7. Métodos Iterativos Estacionarios

Descomposición: $A = D + L_s + U_s$. Esquema: $x^{(k+1)} = T x^{(k)} + c$. Error: $e^{(k)} = x^{(k)} - x^* = T^k e^{(0)}$.

Resultado Clave

Convergencia $\forall x^{(0)} \Leftrightarrow \rho(T) < 1$. Condición suficiente: $\|T\| < 1$. Prueba: $\|e^{(k)}\| \leq \|T\|^k \|e^{(0)}\| \rightarrow 0$. Nota: $\rho(T) \leq \|T\|$, así que $\|T\| < 1$ implica $\rho(T) < 1$, pero no al revés.

7.1. Jacobi

[title=Método de Jacobi] Dado $x^{(0)}$. Para $k = 0, 1, \dots$ hasta convergencia:

1. Para $i = 1, \dots, n$: $x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right)$
2. Parar si $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$.

$T_J = -D^{-1}(L_s + U_s)$, $c_J = D^{-1}b$. Costo/iter: $O(n^2)$ (matriz densa) o $O(\text{nnz})$ (sparse).

Paralelizable: todos los $x_i^{(k+1)}$ se calculan simultáneamente (no dependen entre sí).

$$T_J = -D^{-1}(L_s + U_s), \quad x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right).$$

Resultado Clave

Jacobi converge si A es EDD ($|a_{ii}| > \sum_{j \neq i} |a_{ij}| \forall i$). $(T_J)_{ij} = -a_{ij}/a_{ii}$ ($j \neq i$), cero en diagonal. $\|T_J\|_\infty = \max_i \sum_{j \neq i} |a_{ij}/a_{ii}| \stackrel{\text{EDD}}{<} 1$. □

Convergencia para $A = \begin{bmatrix} 2 & \alpha \\ \alpha & 1 \end{bmatrix}$: $T_J = \begin{bmatrix} 0 & -\alpha/2 \\ -\alpha & 0 \end{bmatrix}$, $\rho(T_J) = |\alpha|/\sqrt{2}$. Converge $\Leftrightarrow |\alpha| < \sqrt{2}$.

Ejemplo iteración: $A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}$, $b = (9, 5)^T$, $x^* = (2, 1)^T$, $x^{(0)} = (0, 0)^T$. $x_1^{(1)} = 9/4 = 2,25$, $x_2^{(1)} = 5/3 \approx 1,67$. $x_1^{(2)} = (9 - 5/3)/4 = 11/6 \approx 1,83$, $x_2^{(2)} = (5 - 9/4)/3 = 11/12 \approx 0,92$. (Converge a $(2, 1)$.)

7.2. Gauss-Seidel

[title=Método de Gauss-Seidel] Dado $x^{(0)}$. Para $k = 0, 1, \dots$ hasta convergencia:

1. Para $i = 1, \dots, n$: $x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right)$
2. Parar si $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$.

$T_{GS} = -(D + L_s)^{-1}U_s$. Usa los valores más recientes $(x_j^{(k+1)})$ para $j < i$.

Secuencial: no paralelizable directamente; compensado por mayor velocidad de convergencia.

$T_{GS} = -(D + L_s)^{-1}U_s$. Usa valores recién calculados inmediatamente:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right).$$

Mismo ejemplo: $x_1^{(1)} = 9/4 = 2,25$; $x_2^{(1)} = (5 - 2,25)/3 = 0,917$ (usa $x_1^{(1)}$ ya actualizado). $x_1^{(2)} = (9 - 0,917)/4 = 2,02$. Converge más rápido que Jacobi.

Condición $|\beta| < 25$ (frecuente en exámenes): $A = \begin{bmatrix} -10 & 2 \\ \beta & 5 \end{bmatrix}$: $\rho(T_J) = \sqrt{|\beta|/25}$, $\rho(T_{GS}) = |\beta|/25$. Ambos convergen $\Leftrightarrow |\beta| < 25$. EDD (fila 2) $\Rightarrow |\beta| < 5$ (suficiente).

7.3. Richardson

[title=Método de Richardson] Elegir $\alpha > 0$. Dado $x^{(0)}$. Para $k = 0, 1, \dots$:

$$x_{k+1} = x_k + \alpha \underbrace{(b - Ax_k)}_{r_k} = (I - \alpha A)x_k + \alpha b.$$

Matriz de iteración: $B = I - \alpha A$, $d = \alpha b$. Converge si $\rho(I - \alpha A) < 1$.

Para A SPD: converge $\Leftrightarrow 0 < \alpha < 2/\lambda_{\max}$. Óptimo: $\alpha^* = \frac{2}{\lambda_{\min} + \lambda_{\max}}$, $\rho_{\min} = \frac{\kappa - 1}{\kappa + 1}$.

8. Métodos No Estacionarios (SPD)

Para A SPD, minimizar $\phi(x) = \frac{1}{2}x^T A x - b^T x$ (su mínimo es la solución de $Ax = b$).

8.1. Mínimo Descenso

Idea: moverse en dirección del residuo $r_k = b - Ax_k$ (gradiente negativo de ϕ). El paso t_k minimiza ϕ a lo largo de r_k .

[title=Mínimo Descenso] $r_0 = b - Ax_0$. Para $k = 0, 1, \dots$: $t_k = \langle r_k, r_k \rangle / \langle r_k, Ar_k \rangle$; $x_{k+1} = x_k + t_k r_k$; $r_{k+1} = r_k - t_k Ar_k$.

Resultado Clave

Prueba: $r_{k+1} \perp r_k \cdot \langle r_{k+1}, r_k \rangle = \langle r_k, r_k \rangle - t_k \langle Ar_k, r_k \rangle = \langle r_k, r_k \rangle - \frac{\langle r_k, r_k \rangle}{\langle r_k, Ar_k \rangle} \langle Ar_k, r_k \rangle = 0. \quad \square$

Consecuencia: trayectoria en zigzag; lento para $\kappa(A) \gg 1$.

8.2. Gradientes Conjugados (GC)

Idea: elegir direcciones A -conjugadas ($\langle u_i, Au_j \rangle = 0$ para $i \neq j$). Convergencia en $\leq n$ pasos exactos.

[title=Gradientes Conjugados] $r_0 = b - Ax_0$, $u_0 = r_0$, $c = \langle r_0, r_0 \rangle$. Para $k = 1, 2, \dots$:

1. $z = Au_{k-1}$; $t_k = c / \langle u_{k-1}, z \rangle$
2. $x_k = x_{k-1} + t_k u_{k-1}$; $r_k = r_{k-1} - t_k z$
3. Si $\langle r_k, r_k \rangle < \varepsilon$, salir.
4. $u_k = r_k + (\langle r_k, r_k \rangle / c) u_{k-1}$; $c = \langle r_k, r_k \rangle$

Resultado Clave

Propiedades clave (frecuentes en exámenes):

- $r_{k+1} = r_k - t_k Au_k$.
- $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$.
- $t_k = \langle u_k, r_0 \rangle / \langle u_k, Au_k \rangle$ (por A -conjugacidad y $r_k \perp u_j$ para $j < k$).
- $r_{k+1} \perp r_j$ para todo $j \leq k$ (pues $\text{span}\{r_j\} = \text{span}\{u_j\}$ y $r_{k+1} \perp u_j$).

Fórmulas alternativas:

$$t_k = \frac{\langle r_k, r_k \rangle}{\langle u_k, Au_k \rangle}, \quad \beta_k = -\frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle}.$$

Prueba de t_k : $\langle u_k, r_k \rangle = \langle r_k, r_k \rangle$ (pues $\langle u_{k-1}, r_k \rangle = 0$). Prueba de β_k : de $Au_k = (r_k - r_{k+1})/t_k$ y $\langle r_{k+1}, r_k \rangle = 0$.

Identificar A, b, c en $q(x) = \frac{1}{2}x^T Ax - b^T x + c$: coef. de x_i^2 es $a_{ii}/2$; coef. de $x_i x_j$ ($i \neq j$) es a_{ij} ; coef. de x_i lineal es $-b_i$.

Ejemplo: $q = 3x_1^2 - 2x_1x_2 + x_1x_3 - x_3^2 + x_3 - x_1 + 5$. $A = \begin{bmatrix} 6 & -2 & 1 \\ -2 & 0 & 0 \\ 1 & 0 & -2 \end{bmatrix}$, $b = (1, 0, -1)^T$, $c = 5$.

9. Número de Condición y Hessenberg

$\kappa(A) = \|A\| \|A^{-1}\|$. Con SVD: $\kappa_2(A) = \sigma_1/\sigma_n$.

Resultado Clave

$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|}$. A mal condicionada si $\kappa(A) > 10^{d-p}$. Regla: $\kappa(A) \approx 10^k \Rightarrow$ se pierden $\approx k$ dígitos.

LU para matrices de Hessenberg ($a_{ij} = 0$ para $i > j + 1$): cada paso crea un solo multiplicador, sin relleno. Costo $O(n^2)$ en lugar de $O(n^3/3)$.

Ejemplo: $A = \begin{bmatrix} 4 & 2 & 3 \\ -2 & 1 & -2 \\ 0 & 1 & 2 \end{bmatrix}$. $\ell_{21} = -1/2$: $R_2 \rightarrow (0, 2, -1/2)$; $\ell_{32} = 1/2$: $R_3 \rightarrow (0, 0, 9/4)$. $L = \begin{bmatrix} 1 & 0 & 0 \\ -1/2 & 1 & 0 \\ 0 & 1/2 & 1 \end{bmatrix}$, $U = \begin{bmatrix} 4 & 2 & 3 \\ 0 & 2 & -1/2 \\ 0 & 0 & 9/4 \end{bmatrix}$.

10. Análisis Computacional: ¿Cuándo Usar Qué?

10.1. Métodos directos vs. iterativos

Resultado Clave

Usa un método directo (LU, Cholesky, QR) cuando n es pequeño-mediano ($n \lesssim 10^4$), la matriz es densa, necesitas resolver muchos sistemas con la misma A (factoriza una vez, resuelve varias), o necesitas solución exacta.

Usa un método iterativo (Jacobi, GS, GC) cuando n es grande ($n \gtrsim 10^5$), la matriz es *sparse* (muchos ceros), y una aproximación buena basta. La iteración explota la estructura: Ax cuesta $O(\text{nnz})$ en lugar de $O(n^2)$.

10.2. Comparación de factorizaciones directas

Método	Costo	Hipótesis	Estabilidad	Cuándo es la mejor opción
LU sin pivoteo	$n^3/3$	Menores $\neq 0$	Puede fallar	Matrices con estructura especial que garantiza estabilidad
LU con pivoteo ($PA = LU$)	$n^3/3$	A no singular	Buena	Caso general; uso estándar en <code>lu()</code> de Matlab
Cholesky (LL^T)	$n^3/6$	A SPD	Excelente (sin pivoteo)	A SPD: 2× más rápido y más estable que LU
QR Gram-Schmidt	$2mn^2$	Cols. LI	Regular	Mínimos cuadrados, matrices pequeñas
QR Householder	$2mn^2$	Cualquier A	Excelente	Mínimos cuadrados, preferible siempre a G-S
SVD	$O(mn^2)$	Cualquier A	Perfecta	Rango, cond., comp. de imágenes; muy costosa
Hessenberg LU	$O(n^2)$	Estructura Hess.	Buena	Matrices de Hessenberg (muy rápido)

Ventaja de Cholesky sobre LU para SPD:

- La mitad de operaciones: $n^3/6$ vs. $n^3/3$.
- No requiere pivoteo: la SPD garantiza pivotes positivos.
- **Test de SPD gratis:** si el algoritmo falla ($\sqrt{\text{negativo}}$), la matriz no es SPD.
- L tiene la misma sparsity que A : ventajoso en problemas sparse.

Ventaja de QR Householder sobre Gram-Schmidt:

- G-S clásico acumula errores de redondeo: las columnas de Q pierden ortogonalidad.
- G-S modificado mejora, pero Householder es *numéricamente óptimo*.
- Householder duplica el costo de GS-clásico pero con estabilidad comprobada.
- Para MC: resolver $R_1 \hat{x} = c_1$ tiene $\kappa(R_1) = \kappa(A)$; las ecuaciones normales tienen $\kappa(A^T A) = \kappa(A)^2$ — se pierde el doble de dígitos.

Desventajas de SVD:

- Costo $O(mn^2)$ muy superior a QR; solo se justifica cuando se necesitan valores singulares o compresión de rango.
- Implementación compleja (requiere iteraciones para los autovalores de $A^T A$).

10.3. Comparación de métodos iterativos estacionarios

Método	T	Ventaja	Desventaja
Jacobi	$-D^{-1}(L_s + U_s)$	Paralelizable	Más lento que GS; puede divergir donde GS converge
Gauss-Seidel	$-(D + L_s)^{-1}U_s$	2× más rápido que Jacobi	Secuencial (no paralelizable)
Richardson	$I - \alpha A$	Muy simple	Necesita conocer $\lambda_{\text{máx}}$ para elegir α óptimo

¿Cuándo converge cada uno?

- **EDD** $\Rightarrow$ Jacobi y GS convergen (condición suficiente, no necesaria).
- **SPD** $\Rightarrow$ GS converge (Teorema de Ostrowski-Reich).
- GS tiene $\rho(T_{GS}) = \rho(T_J)^2$ para muchas matrices (converge en mitad de iteraciones).
- Richardson SPD: óptimo con $\alpha^* = 2/(\lambda_{\text{mín}} + \lambda_{\text{máx}})$, $\rho = (\kappa - 1)/(\kappa + 1)$.

10.4. Mínimo Descenso vs. Gradientes Conjugados (SPD)

	Mínimo Descenso	Gradientes Conjugados
Dirección	r_k (residuo)	u_k (A -conjugada a $u_0, \dots, u_{k-1}$)
Paso	$t_k = \ r_k\ ^2 / r_k^T A r_k$	$t_k = \ r_k\ ^2 / u_k^T A u_k$
Convergencia	$O(\kappa)$ iteraciones	$\leq n$ exactas; $O(\sqrt{\kappa})$ práctica
Trayectoria	Zigzag (residuos consecutivos $\perp$)	Suave; minimiza en subespacio de Krylov
Desventaja	Lento para $\kappa \gg 1$	Más complejo; necesita actualizar u_k

Cuidado

Resumen de la jerarquía para $Ax = b$ SPD: $GC \gg MD > GS > \text{Jacobi}$ (en velocidad de convergencia para sistemas grandes). Para sistemas pequeños densos: Cholesky directo siempre gana.

Precondicionamiento (GC precondicionado): aplicar GC a $\tilde{A}\tilde{x} = \tilde{b}$ donde $\tilde{A} = M^{-1/2}AM^{-1/2} \approx I$. El número de condición efectivo baja de $\kappa(A)$ a $\kappa(M^{-1}A) \ll \kappa(A)$. Opciones comunes: diagonal (Jacobi), Cholesky incompleto (ILU), multigrid.

11. Tabla Resumen y Patrón de Examen

Método	Hipótesis	Costo	Uso principal
$A = LU$	Menores $\neq 0$	$n^3/3$	Resolver $Ax = b$, múltiples b
$PA = LU$	A no singular	$n^3/3$	Siempre existe con pivoteo
$A = LL^T$ Cholesky	A SPD	$n^3/6$	SPD: más rápido, sin pivoteo
$A = QR$ (G-S)	Cols. LI	$2mn^2$	MC estable
$A = QR$ (Householder)	Cualquier A	$2mn^2$	MC, más estable que G-S
$A = U\Sigma V^T$ SVD	Cualquier A	$O(mn^2)$	Rango, κ , compresión
Hessenberg LU	Estructura	$O(n^2)$	Rápido por estructura
Jacobi / GS	Conv.: $\rho(T) < 1$	por iter. $O(n^2)$	Sistemas grandes
Mínimo Des-censo	A SPD	por iter. $O(n^2)$	SPD, convergencia lenta
Grad. Conjugados	A SPD	$\leq n$ iters.	SPD, convergencia rápida

Resultado Clave**Top 10 preguntas de examen (patrón I-2016 a I-2026):**

1. Demostrar propiedades de Householder: simétrica, ortogonal ($H^2 = I$), $\det(H) = -1$, $Hv = -v$, aniquilación.
2. Demostrar $b - A\hat{x} \perp a_i$ (residuo MC ortogonal a columnas de A).
3. SVD: algoritmo 6 pasos + calcular para una 3×2 .
4. Convergencia Jacobi para $A = \begin{bmatrix} 2 & \alpha \\ \alpha & 1 \end{bmatrix}$: $|\alpha| < \sqrt{2}$.
5. Identificar B y d de un método iterativo dado como pseudocódigo ($\Rightarrow$ Gauss-Seidel).
6. Probar $r_{k+1} \perp r_k$ en Mínimo Descenso.
7. GC: probar $r_{k+1} \perp r_j$ para todo $j \leq k$.
8. Fórmulas alternativas GC: $t_k = \|r_k\|^2 / \langle u_k, Au_k \rangle$, $\beta_k = -\|r_{k+1}\|^2 / \|r_k\|^2$.
9. GS para n variables: pseudocódigo + fórmula con suma parcial actualizada.
10. Unicidad de Cholesky: $R = M^{-1}L$ ortogonal + triangular inferior $\Rightarrow R = I$.