

Solucionario: Exámenes de Cálculo Científico

Temas 3 y 4 — Parcial 2 (I-2026)

Luisdavid Colina — 24.766.381

UCV, Escuela de Computación, I-2026

Índice temático de ejercicios

Matrices ortogonales	Producto de ortogonales (§1.1), $A^T A$ simétrica/SPD (§3.1), Householder — propiedades completas (§12)
SVD	Algoritmo (§10.1), Cálculo 3×2 (§10.2)
Factorización QR	Gram-Schmidt (§1.4), Householder + MC (§3.4), Ejemplo Householder 3×3 (§7), $Q^T L$ triangular superior (§11.2), Práctica QR (§6)
Factorización LU	LU sin pivoteo (§5.1), Valores de ξ sin LU (§5.2), Tridiagonal (§5.3), PA=LU con pivoteo (§5.4), Unicidad (§9.4), Hessenberg (§11.1, §11.1.2)
Factorización Cholesky	Algoritmo 3×3 (§9.1), Cholesky por bloques (§8), Unicidad (§15.1)
Minimos cuadrados	Residuo ortogonal (§1.2, §3.2), Escalar α (§9.2), Constante óptima = media (§2.2), QR para MC (§3.4), Regresión lineal (§13.1)
Métodos iterativos	Convergencia Jacobi con α (§1.3), Jacobi para EDD (§2.3), Convergencia $\ T\ < 1$ (§3.3), Gauss-Seidel (código) (§2.4), Gauss-Seidel (identificación B, d) (§10.3), Gauss-Seidel (n variables, pseudocódigo) (§13.5), Condición sobre β (§13.3), Método de Richardson (§13.4), Sistemas transpuestos con LU (§9.5)
Mínimo Descenso y GC	$r_{k+1} \perp r_k$ en MD (§4.2), $r_{k+1} \perp r_j$ en GC (§10.6), Propiedades de GC (a)–(c) (§4.5), Formas alternativas t_k, β_k (§14.4), Identificar A, b, c en cuadrática (§14.1), Escalar óptimo (§4.3), Número de condición (§4.1)

Índice de archivos fuente

Archivos en `exámenes/` y `practicas/` del repositorio. Los números de página enlazan directamente a la solución.

Exámenes (exámenes/)

PT2-2016-II.pdf	Segundo Parcial 2016-II (pág. 3)
Q2-2016-II.pdf	Quiz 2 — 2016-II (pág. 5)
Q2-2017-I.pdf	Quiz 2 — 2017-I (pág. 6)
QuizParcial2-II2024CLAVE.pdf	Quiz 2, 2024-II (pág. 8) + Parcial II, 2024-II (pág. 9)
SolQuiz1-I2025.pdf	Cholesky por bloques (Quiz 1, 2024-II) (pág. 12)
Parcial1-I2025CLAVE.pdf	Parcial 1, I-2025 — temas 1-2, no cubre este solucionario
SolQuiz2-I2025.pdf	Pendiente de incorporar al solucionario
parciales_quices.pdf	Colección histórica de varios exámenes (referencia)
PT3- Cálculo Cientifico 2024-I.pdf	Parcial 3, 2024-I — fuera del alcance del Parcial 2
Parcial I.pdf	Primer parcial (temas 1-2) — referencia

Prácticas (practicas/)

Practica-LU.pdf	Práctica: Factorización LU (28 May 2026) (pág. 10)
Practica-QR.pdf	Práctica: Factorización QR (04 Jun 2026) (pág. 11)
QR_Householder.pdf	Ejemplo QR con Householder (05 Jun 2026) (pág. 11)
Practica-LSP-Jacobi-GaussSeidel.pdf	Práctica: LSP y Métodos Iterativos (11 Jun 2026) (pág. 20)
Practica-GradientesConjugados.pdf	Práctica: Gradientes Conjugados (18 Jun 2026) (pág. 22)

1. Segundo Parcial 2016-II

Segundo Parcial 2016-II — 4 preguntas de 5 puntos c/u

P1. Sean $Q_1, \dots, Q_n \in \mathbb{R}^{m \times m}$ matrices ortogonales. Demuestre que el producto $Q = Q_1 Q_2 \cdots Q_n$ también es ortogonal.

P2. Sea $A \in \mathbb{R}^{m \times n}$ con $m > n$ y $b \in \mathbb{R}^m$. Demuestre que si $\hat{x}$ minimiza $\|b - Ax\|_2$, entonces el residuo $r = b - A\hat{x}$ es ortogonal a cada columna a_i de A .

P3. Sea $A = \begin{pmatrix} 2 & \alpha \\ \alpha & 1 \end{pmatrix}$. Determine todos los valores de $\alpha \in \mathbb{R}$ para los cuales el método de Jacobi converge al aplicarlo al sistema $Ax = b$ (para cualquier b y cualquier $x^{(0)}$).

P4. Calcule la factorización QR de $A = \begin{pmatrix} 1 & 3 \\ 1 & -3 \\ 1 & 4 \\ 1 & -4 \end{pmatrix}$ usando el proceso de Gram-Schmidt.

1.1. P1: Producto de matrices ortogonales es ortogonal

Idea: $(AB)^T = B^T A^T$, así que la transpuesta del producto *invierte* el orden. Los factores adyacentes $Q_i^T Q_i = I$ se cancelan en cascada (efecto telescópico).

Demostración. Sean $Q_1, \dots, Q_n$ ortogonales ($Q_i^T Q_i = I$) y $Q = Q_1 Q_2 \cdots Q_n$.

$$Q^T Q = (Q_n^T \cdots Q_1^T)(Q_1 \cdots Q_n).$$

Se cancelan de adentro hacia afuera: $\underbrace{Q_1^T Q_1}_{=I} \rightarrow \underbrace{Q_2^T Q_2}_{=I} \rightarrow \cdots \rightarrow Q_n^T Q_n = I.$

□

□

1.2. P2: Residuo ortogonal al espacio columna en MC

Idea: Para minimizar $\|b - Ax\|_2^2$ igualamos su gradiente a cero. El gradiente es A^T aplicado al residuo $b - Ax$; igualarlo a cero dice exactamente que el residuo es ortogonal a cada columna de A .

Demostración. Sea $f(x) = \|b - Ax\|_2^2 = b^T b - 2x^T A^T b + x^T A^T A x$ (expandiendo $\|b - Ax\|_2^2$).

Gradiente respecto a x e igualado a cero:

$$\nabla_x f = -2A^T b + 2A^T A x = 0 \implies A^T \underbrace{(b - Ax)}_{\text{residuo}} = 0.$$

Escribiendo $A = [a_1 | \cdots | a_n]$, la ecuación $A^T(b - Ax) = 0$ equivale a $a_i^T(b - Ax) = 0$ para todo i , es decir el residuo $b - A\hat{x}$ es ortogonal a cada columna de A . □

Interpretación geométrica: $A\hat{x}$ es la proyección de b sobre $\text{col}(A)$. El residuo $b - A\hat{x}$ cae perpendicularmente al subespacio columna.

1.3. P3: Convergencia de Jacobi para $A = \begin{pmatrix} 2 & \alpha \\ \alpha & 1 \end{pmatrix}$

Construcción de la iteración de Jacobi. Se descompone $A = D + L + U$ donde:

- D = diagonal de A ,

- L = parte estrictamente triangular inferior,
- U = parte estrictamente triangular superior.

La ecuación $Ax = b$ se reescribe $Dx = -(L + U)x + b$, despejando la iteración:

$$x_{k+1} = \underbrace{-D^{-1}(L + U)}_{T_J} x_k + D^{-1}b.$$

Jacobi **converge** $\Leftrightarrow \rho(T_J) < 1$ (radio espectral de la matriz de iteración).

Para $A = \begin{bmatrix} 2 & \alpha \\ \alpha & 1 \end{bmatrix}$:

$$D = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}, \quad L + U = \begin{pmatrix} 0 & \alpha \\ \alpha & 0 \end{pmatrix} \Rightarrow T_J = -\begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & \alpha \\ \alpha & 0 \end{pmatrix} = \begin{pmatrix} 0 & -\alpha/2 \\ -\alpha & 0 \end{pmatrix}.$$

Autovalores de T_J :

$$\det(T_J - \lambda I) = \lambda^2 - \frac{\alpha^2}{2} = 0 \Rightarrow \lambda_{1,2} = \pm \frac{|\alpha|}{\sqrt{2}}, \quad \rho(T_J) = \frac{|\alpha|}{\sqrt{2}}.$$

Jacobi converge $\Leftrightarrow \rho(T_J) < 1 \Leftrightarrow |\alpha|/\sqrt{2} < 1 \Leftrightarrow |\alpha| < \sqrt{2}$.

1.4. P4: Factorización QR por Gram-Schmidt

Idea (Gram-Schmidt): Construir columnas ortonormales q_i a partir de las columnas a_i de A . En cada paso: (1) proyectar a_j sobre los q_i ya calculados y restar esas proyecciones $\rightarrow$ vector v_j ortogonal a todos los anteriores; (2) normalizar: $q_j = v_j/\|v_j\|$. Los coeficientes r_{ij} son las proyecciones.

$$A = \begin{pmatrix} 1 & 3 \\ 1 & -3 \\ 1 & 4 \\ 1 & -4 \end{pmatrix}, \text{ columnas } a_1 = (1, 1, 1, 1)^T, \quad a_2 = (3, -3, 4, -4)^T.$$

Paso 1 — primera columna ortonormal:

$$v_1 = a_1 = (1, 1, 1, 1)^T, \quad \|v_1\| = 2, \quad q_1 = \frac{v_1}{2} = \frac{1}{2}(1, 1, 1, 1)^T, \quad r_{11} = \|v_1\| = 2.$$

Paso 2 — ortogonalizar a_2 respecto a q_1 :

$$r_{12} = q_1^T a_2 = \frac{1}{2}(3 - 3 + 4 - 4) = 0 \Rightarrow v_2 = a_2 - r_{12} q_1 = a_2 = (3, -3, 4, -4)^T.$$

(El resultado $r_{12} = 0$ indica que $a_1 \perp a_2$; Q ya es ortogonal sin modificar a_2 .)

$$\|v_2\| = \sqrt{9 + 9 + 16 + 16} = \sqrt{50} = 5\sqrt{2}, \quad q_2 = \frac{(3, -3, 4, -4)^T}{5\sqrt{2}}, \quad r_{22} = 5\sqrt{2}.$$

$$Q = \begin{pmatrix} 1/2 & 3/(5\sqrt{2}) \\ 1/2 & -3/(5\sqrt{2}) \\ 1/2 & 4/(5\sqrt{2}) \\ 1/2 & -4/(5\sqrt{2}) \end{pmatrix}, \quad R = \begin{pmatrix} 2 & 0 \\ 0 & 5\sqrt{2} \end{pmatrix}.$$

2. Quiz 2 — 2016-II

Quiz 2 (2016-II) — 4 preguntas de 5 puntos c/u

- P1.** Sea $H = I - \frac{2vv^T}{v^T v}$ con $v \in \mathbb{R}^n$, $v \neq 0$. Demuestre que H es simétrica y ortogonal.
- P2.** Dados $y_1, \dots, y_n \in \mathbb{R}$, encuentre la constante C^* que minimiza $E(C) = \sum_{i=1}^n (y_i - C)^2$. Demuestre que C^* es la media aritmética de los datos.
- P3.** Sea $A \in \mathbb{R}^{n \times n}$ estrictamente diagonalmente dominante (EDD): $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$ para todo i . Demuestre que el método de Jacobi converge para cualquier $x^{(0)}$.
- P4.** Escriba el pseudocódigo (o código Matlab) del método de Gauss-Seidel para resolver el sistema $Ax = b$ con criterio de parada $\|x^{(k+1)} - x^{(k)}\|_\infty < \varepsilon$.

2.1. P1: Householder es simétrica y ortogonal

$$\text{Sea } H = I - \frac{2vv^T}{v^T v}.$$

¿Qué hay que probar? (1) Que $H^T = H$ (simétrica). (2) Que $H^T H = I$ (ortogonal). Dado que ya probaremos (1), la ortogonalidad equivale a mostrar $H^2 = I$, es decir que H es su propia inversa.

Demostración. Parte 1: H es simétrica.

Transponemos cada término de $H = I - \frac{2}{v^T v} vv^T$:

$$H^T = I^T - \frac{2}{v^T v} (vv^T)^T.$$

El factor $2/(v^T v)$ es escalar (no cambia al transponer). La transpuesta de un producto exterior vv^T es $(vv^T)^T = (v^T)^T v^T = vv^T$ (se invierte el orden pero v^T transpuesta es v y v transpuesta es v^T). Luego $H^T = I - \frac{2}{v^T v} vv^T = H$. $\square$

Parte 2: H es ortogonal.

Como $H = H^T$, la condición $H^T H = I$ equivale a $H^2 = I$. Calculamos H^2 expandiendo el cuadrado de un binomio matricial:

$$H^2 = \left(I - \frac{2vv^T}{v^T v} \right)^2 = I - \frac{4vv^T}{v^T v} + \frac{4v \underbrace{(v^T v)}_{\text{escalar}} v^T}{(v^T v)^2}.$$

En el último término, $(v^T v)$ es un escalar que sale del producto $v^T \cdot v$. Simplificando:

$$H^2 = I - \frac{4vv^T}{v^T v} + \frac{4(v^T v) vv^T}{(v^T v)^2} = I - \frac{4vv^T}{v^T v} + \frac{4vv^T}{v^T v} = I. \quad \square$$

Los dos términos de vv^T se cancelan exactamente porque el factor del término cúbico simplifica a $4/(v^T v)$, igual que el término cuadrático. $\square$

Interpretación geométrica: H es una *reflexión* respecto al hiperplano $\{x : v^T x = 0\}$. Reflexionar dos veces da la identidad ($H^2 = I$), lo que hace evidente que H sea su propia inversa. La simetría de H expresa que la reflexión de y en x tiene la misma componente que la reflexión de x en y .

2.2. P2: Constante óptima en MC es la media aritmética

¿Qué hay que probar? Que el valor de C que minimiza la suma de desviaciones cuadráticas $E(C) = \sum (y_i - C)^2$ es exactamente el promedio de los datos.

¿Por qué esperar ese resultado? Intuitivamente, si C es muy grande, todos los $(y_i - C)^2$ son grandes. Si C es muy pequeño, igual. El mínimo debe estar “en el centro” de los datos, que es la media.

Demostración. Definimos $E(C) = \sum_{i=1}^n (y_i - C)^2$. Este es un polinomio de grado 2 en C con coeficiente líder $n > 0$, así que tiene un único mínimo global (parábola hacia arriba).

Para encontrarlo, derivamos e igualamos a cero:

$$\frac{dE}{dC} = \sum_{i=1}^n 2(y_i - C) \cdot (-1) = -2 \sum_{i=1}^n (y_i - C) = 0.$$

Distribuyendo la suma:

$$\sum_{i=1}^n y_i - nC = 0 \implies C^* = \frac{\sum_{i=1}^n y_i}{n} = \bar{y}.$$

Es mínimo y no máximo porque $E''(C) = 2n > 0$ (segunda derivada positiva). □ □

Vínculo con ecuaciones normales: en notación matricial, el problema es $\min_C \|y - C\mathbf{1}\|^2$ con $A = \mathbf{1} = (1, \dots, 1)^T$ y variable escalar C . La ecuación normal $A^T A C = A^T y$ da $nC = \sum y_i$, la misma respuesta.

2.3. P3: Jacobi converge para matrices EDD

¿Qué hay que probar? Que si A es EDD, el radio espectral de T_J es menor que 1 (o equivalentemente, que la norma $\|T_J\|_\infty < 1$, lo que implica convergencia).

Estrategia: usaremos la condición *suficiente* $\|T\| < 1$. Para ello expresamos T_J explícitamente y calculamos su norma ∞ (máxima suma de fila en valor absoluto).

Demostración. Paso 1: ¿cómo es T_J para una matriz general A ?

Jacobi resuelve $Dx^{(k+1)} = -(L_s + U_s)x^{(k)} + b$, así que:

$$T_J = -D^{-1}(L_s + U_s), \quad (T_J)_{ij} = \begin{cases} -a_{ij}/a_{ii} & i \neq j \\ 0 & i = j. \end{cases}$$

Es decir: los elementos fuera de la diagonal de T_J son los cocientes a_{ij}/a_{ii} cambiados de signo; la diagonal de T_J es cero (en Jacobi la diagonal de A se mueve al lado derecho).

Paso 2: calcular $\|T_J\|_\infty$ y usar EDD.

La norma infinito de una matriz es el máximo de las sumas de fila en valor absoluto:

$$\|T_J\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |(T_J)_{ij}| = \max_i \sum_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|}.$$

(El término $j = i$ es cero, no contribuye.)

Como A es EDD, para cada fila i : $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$, que equivale a $\sum_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|} < 1$.

Por tanto $\|T_J\|_\infty < 1$, y por la condición suficiente de convergencia, Jacobi converge. □ □

Nota importante: la condición EDD es suficiente pero *no necesaria*. Jacobi puede converger aunque A no sea EDD (si $\rho(T_J) < 1$ por otras razones). La EDD garantiza convergencia sin necesidad de calcular autovalores.

2.4. P4: Código Gauss-Seidel

Diferencia clave respecto a Jacobi: Jacobi guarda el vector $x^{(k)}$ completo y lo usa para calcular *todo* $x^{(k+1)}$. Gauss-Seidel actualiza x_i en el momento y lo usa de inmediato para calcular x_{i+1} . En la fórmula:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij} \underbrace{x_j^{(k+1)}}_{\text{ya calculado}} - \sum_{j>i} a_{ij} \underbrace{x_j^{(k)}}_{\text{aún no actualizado}} \right).$$

Listing 1: Método de Gauss-Seidel (Matlab)

```

1 function x = gauss_seidel(A, b, x0, tol, max_iter)
2     n = length(b);
3     x = x0; % vector inicial
4     for k = 1:max_iter
5         x_old = x; % guardar copia para el criterio de parada
6         for i = 1:n
7             % x(1..i-1) ya tiene los valores NUEVOS del paso k+1
8             % x_old(i+1..n) tiene los valores VIEJOS del paso k
9             sum1 = A(i, 1:i-1) * x(1:i-1); % contribucion columnas
10            % ya actualizadas
11            sum2 = A(i, i+1:n) * x_old(i+1:n); % contribucion columnas
12            % aun viejas
13            x(i) = (b(i) - sum1 - sum2) / A(i,i); % despejar x_i de la
14            % ecuacion i
15        end
16        % Criterio de parada: diferencia entre iteraciones consecutivas
17        if norm(x - x_old, inf) < tol
18            fprintf('Convergencia en %d iteraciones.\n', k);
19            return;
20        end
21    end
22    warning('Maximo de iteraciones alcanzado sin convergencia.');
```

¿Por qué funciona actualizar inmediatamente? Porque si $x_j^{(k+1)}$ ya está más cerca de x_j^* que $x_j^{(k)}$, usarlo reduce el error más rápido. Esto es intuitivamente por qué GS converge en general el doble de rápido que Jacobi.

¿Por qué guardar `x_old`? Solo para el criterio de parada. Dentro del bucle interno necesitamos distinguir entre los valores ya actualizados (`x`) y los del paso anterior (`x_old`).

3. Quiz 2 — 2017-I

Quiz 2 2017-I — P1: 4 pts, P2–P3: 5 pts c/u, P4: 6 pts

P1 (4 pts). Sea $A \in \mathbb{R}^{m \times n}$. Demuestre que $A^T A$ es simétrica y semidefinida positiva. ¿Bajo qué condición sobre A es estrictamente positiva definida?

P2 (5 pts). Derive las ecuaciones normales $A^T A \hat{x} = A^T b$ para el problema de mínimos cuadrados $\min_{x \in \mathbb{R}^n} \|b - Ax\|_2^2$.

P3 (5 pts). Sea $x^{(k+1)} = Tx^{(k)} + d$ un esquema iterativo tal que $\|T\| < 1$ para alguna norma matricial subordinada. Demuestre que el esquema converge a la solución fija $x^* = Tx^* + d$ para todo $x^{(0)}$.

P4 (6 pts). Sea $A = \begin{pmatrix} 1 & -17/3 \\ 1 & 0 \\ 1 & 5 \\ 1 & 12 \end{pmatrix}$, $b = (-14/3, 1, 6, 13)^T$. Calcule la factorización QR de A usando reflexiones de Householder y úsela para resolver el problema de mínimos cuadrados $\min_x \|b - Ax\|_2^2$.

3.1. P1: $A^T A$ es simétrica y semi/positivo definida

¿Por qué importa esto? La solución del problema de MC requiere que $A^T A$ sea invertible para que exista solución única. Esto falla cuando las columnas de A son linealmente dependientes (por eso la condición de rango).

Demostración. Simétrica. Basta transponer $A^T A$:

$$(A^T A)^T = A^T \underbrace{(A^T)^T}_{=A} = A^T A.$$

El producto es igual a su transpuesta, luego es simétrica.

Semidefinida positiva. Para cualquier $x \neq 0$, calculamos la forma cuadrática:

$$x^T (A^T A) x = (Ax)^T (Ax) = \|Ax\|_2^2 \geq 0.$$

El truco es reagrupar: $x^T A^T = (Ax)^T$, así que $x^T (A^T A) x = (Ax)^T (Ax)$, que es la norma al cuadrado. Una norma siempre es ≥ 0 .

Estrictamente positiva definida si las columnas de A son L.I.

$\|Ax\|_2^2 = 0 \Leftrightarrow Ax = 0$. Pero si las columnas de A son linealmente independientes, la única combinación lineal nula es la trivial, es decir $x = 0$. Luego $\|Ax\|_2^2 > 0$ para todo $x \neq 0$. $\square \quad \square$

Consecuencia práctica: como $A^T A$ es SPD (con cols. L.I.), tiene una factorización de Cholesky y la solución de MC puede calcularse eficientemente resolviendo $A^T A \hat{x} = A^T b$.

3.2. P2: Ecuaciones normales para MC

Idea: minimizar $f(x) = \|b - Ax\|_2^2$ igualando su gradiente a cero. El gradiente respecto a x resulta ser A^T aplicado al residuo; igualarlo a cero equivale exactamente a que el residuo sea ortogonal al espacio columna de A .

Demostración. Expandiendo: $f(x) = b^T b - 2x^T A^T b + x^T A^T A x$.

Gradiente e igual a cero:

$$\nabla_x f = -2A^T b + 2A^T A x = 0 \implies A^T (b - Ax) = 0 \implies A^T A x^* = A^T b.$$

Como $A^T A$ es SPD cuando A tiene columnas L.I., la solución $x^* = (A^T A)^{-1} A^T b$ es única.

Interpretación: $A^T(b - Ax^*) = 0$ dice que el residuo $b - Ax^*$ es ortogonal a cada columna de A , i.e., $b - Ax^* \perp \text{col}(A)$. El vector Ax^* es la proyección ortogonal de b sobre $\text{col}(A)$. $\square$ $\square$

3.3. P3: Convergencia del esquema iterativo con $\|T\| < 1$

Idea: el método $x_{k+1} = Tx_k + d$ tiene solución fija $x^* = Tx^* + d$. Restando: el error $e^{(k)} = x^{(k)} - x^*$ obedece $e^{(k+1)} = Te^{(k)}$, recursión que da $e^{(k)} = T^k e^{(0)}$. Si $\|T\| < 1$, la norma del error decae geométricamente.

Demostración. Sea x^* el punto fijo: $x^* = Tx^* + d$. Restando de la iteración:

$$e^{(k+1)} = x^{(k+1)} - x^* = T(x^{(k)} - x^*) = Te^{(k)}.$$

Por inducción $e^{(k)} = T^k e^{(0)}$, luego:

$$\|e^{(k)}\| \leq \|T^k\| \|e^{(0)}\| \leq \|T\|^k \|e^{(0)}\| \xrightarrow[k \rightarrow \infty]{\|T\| < 1} 0. \quad \square$$

$\square$

Nota: la condición $\|T\| < 1$ es *suficiente* pero no necesaria; la condición necesaria y suficiente es $\rho(T) < 1$ (radio espectral). Toda norma matricial satisface $\rho(T) \leq \|T\|$.

3.4. P4: QR por Householder y solución MC

Idea (Householder): En cada paso k se construye una reflexión H_k que anula todos los elementos debajo del pivote de la columna k . El vector de Householder es:

$$u = a_k + \text{sgn}(a_{k1})\|a_k\|e_1, \quad H = I - \frac{2}{u^T u} u u^T.$$

(Se suma $\|a_k\|$ cuando $a_{k1} > 0$ para evitar cancelación numérica.)

Después de $\min(m-1, n)$ pasos: $H_p \cdots H_1 A = \begin{bmatrix} R \\ 0 \end{bmatrix}$. Para MC: se aplica la misma secuencia a b , y se resuelve $R_1 x = c_1$ (las primeras n filas).

$$A = \begin{pmatrix} 1 & -17/3 \\ 1 & 0 \\ 1 & 5 \\ 1 & 12 \end{pmatrix}, \quad b = (-14/3, 1, 6, 13)^T.$$

Paso 1 — anular $(2, 1), (3, 1), (4, 1)$:

$$a_1 = (1, 1, 1, 1)^T, \quad \|a_1\| = 2, \quad \text{sgn}(a_{11}) = +1.$$

$$u_1 = a_1 + 2e_1 = (3, 1, 1, 1)^T, \quad u_1^T u_1 = 12, \quad \rho_1 = 2/12 = 1/6.$$

H_1 lleva la primera columna a $(2, 0, 0, 0)^T$. Aplicando a a_2 y b :

$$H_1 a_2 = \frac{1}{3}(17, -34/3, -19/3, 2/3)^T \quad (\text{primer elemento} = r_{11} = 17/3, \text{ resto en submatriz}).$$

$$H_1 b = (23/3, *, *, *)^T \quad (c_1 = 23/3).$$

Paso 2 — anular $(3, 2), (4, 2)$ en la submatriz 3×1 :

Subvector activo: $\hat{a}_2 = (-34/3, -19/3, 2/3)^T$, $\|\hat{a}_2\| = \sqrt{1156 + 361 + 4}/3 = 13$.

$u_2 = \hat{a}_2 + (-13)e_1 = (-34/3 - 13, -19/3, 2/3)^T = (-73/3, -19/3, 2/3)^T$. H_2 (embebida en la submatriz) lleva $\hat{a}_2$ a $(-13, 0, 0)^T$, dando $r_{22} = -13$. $c_2 = -13$.

$$R = \begin{pmatrix} 2 & 17/3 \\ 0 & -13 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}, \quad Q^T b = \begin{pmatrix} 23/3 \\ -13 \\ 0 \\ 0 \end{pmatrix}.$$

Resolver $R_1 \hat{x} = c_1$ (sustitución hacia atrás):

$$-13x_2 = -13 \implies x_2 = 1, \quad 2x_1 + \frac{17}{3}(1) = \frac{23}{3} \implies x_1 = 1.$$

Solución MC: $\hat{x} = (1, 1)^T$, i.e. $\hat{y}(t) = 1 + t$.

4. Quiz 2 y Parcial II — 2024-II

Quiz 2 2024-II (04-06 Feb 2025) — P1: 6 pts, P2: 7 pts, P3: 7 pts

P1 (6 pts). Defina el número de condición $\text{cond}(A) = \|A\| \|A^{-1}\|$. Si $Ax = b$ y $A\hat{x} = b + \delta b$, demuestre la cota $\|\delta x\|/\|x\| \leq \text{cond}(A) \|\delta b\|/\|b\|$. ¿Qué significa que A esté “mal condicionada”?

P2 (7 pts). Sea A simétrica definida positiva. En el método de Mínimo Descenso se define $r_k = b - Ax_k$ y $x_{k+1} = x_k + t_k r_k$ con $t_k = \langle r_k, r_k \rangle / \langle r_k, Ar_k \rangle$. Demuestre que $r_{k+1} \perp r_k$.

P3 (7 pts). Dados $x, y \in \mathbb{R}^m$, encuentre el escalar α^* que minimiza $\|y - \alpha x\|_2$. Expréselo en términos de x e y .

4.1. P1: Numero de condicion y mal condicionamiento

Cota de error en la solución. Si $Ax = b$ y $(A + \delta A)(x + \delta x) = b + \delta b$, se puede demostrar que:

$$\frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \cdot \frac{\|\delta b\|}{\|b\|}, \quad \text{cond}(A) = \|A\| \|A^{-1}\|.$$

El número de condición *amplifica* el error relativo de los datos al error relativo de la solución.

Criterio de mal condicionamiento. Si los datos tienen d dígitos correctos ($\|\delta b\|/\|b\| \leq 10^{-d}$) y se quiere la solución con p dígitos correctos ($\|\delta x\|/\|x\| \leq 10^{-p}$):

$$\text{cond}(A) \cdot 10^{-d} \leq 10^{-p} \iff \text{cond}(A) \leq 10^{d-p}.$$

A está **mal condicionada** si $\text{cond}(A) > 10^{d-p}$. En la práctica: si $\text{cond}(A) \approx 10^k$, se *pierden* aproximadamente k dígitos de precisión.

4.2. P2: Demostracion $r_{k+1} \perp r_k$ en Minimo Descenso

Contexto del método. El Mínimo Descenso minimiza $f(x) = \frac{1}{2}x^T Ax - b^T x$ (función cuadrática con A SPD) moviéndose en la dirección del residuo $r_k = b - Ax_k$. El paso óptimo t_k es el que minimiza f a lo largo de r_k :

$$x_{k+1} = x_k + t_k r_k, \quad t_k = \frac{\langle r_k, r_k \rangle}{\langle r_k, Ar_k \rangle} = \frac{\|r_k\|^2}{r_k^T Ar_k}.$$

Por qué $r_{k+1} \perp r_k$: t_k fue elegido exactamente para minimizar f en la dirección r_k , lo que equivale a que el gradiente en x_{k+1} sea ortogonal a r_k .

Demostración. $r_{k+1} = b - Ax_{k+1} = b - A(x_k + t_k r_k) = r_k - t_k A r_k$. Entonces:

$$\langle r_{k+1}, r_k \rangle = \langle r_k, r_k \rangle - t_k \langle A r_k, r_k \rangle = \langle r_k, r_k \rangle - \frac{\langle r_k, r_k \rangle}{\langle r_k, A r_k \rangle} \langle A r_k, r_k \rangle = 0. \quad \square$$

□

4.3. P3: Escalar óptimo $\hat{\alpha} = \arg \min \|y - \alpha x\|_2$

¿Qué estamos haciendo? Este es el problema de MC más simple posible: A es un solo vector columna x , la variable de optimización es el escalar α , y queremos encontrar el múltiplo de x que más se acerca a y .

¿Cuál es la interpretación geométrica? $\hat{\alpha}$ es el coeficiente de la proyección ortogonal de y sobre la recta $\{t \cdot x : t \in \mathbb{R}\}$. La proyección es $\hat{\alpha}x$, y el residuo $y - \hat{\alpha}x$ queda perpendicular a x .

Demostración. Definimos $f(\alpha) = \|y - \alpha x\|_2^2 = (y - \alpha x)^T (y - \alpha x) = \|y\|^2 - 2\alpha x^T y + \alpha^2 \|x\|^2$.

Derivando respecto al escalar α e igualando a cero:

$$\frac{df}{d\alpha} = -2x^T y + 2\alpha x^T x = 0 \implies \hat{\alpha} = \frac{x^T y}{x^T x}.$$

Es mínimo porque $f'' = 2\|x\|^2 > 0$ (parábola hacia arriba). □

□

Verificación de la condición de ortogonalidad: $y - \hat{\alpha}x \perp x$?

$$x^T (y - \hat{\alpha}x) = x^T y - \hat{\alpha} x^T x = x^T y - \frac{x^T y}{x^T x} \cdot x^T x = 0. \checkmark$$

Parcial II 2024-II — P1: 7 pts, P2: 9 pts, P3: 4 pts

P1 (7 pts). Si $Ax = b$ y $(A + \delta A)(x + \delta x) = b + \delta b$, demuestre la cota de perturbación $\|\delta x\|/\|x\| \leq \text{cond}(A) \|\delta b\|/\|b\|$.

P2 (9 pts). Sean $\{u_k\}$ las direcciones de búsqueda del método de Gradientes Conjugados aplicado a $Ax = b$ (A SPD) y $\{r_k\}$ los residuos correspondientes. Demuestre:

$$(a) r_{k+1} = r_k - t_k A u_k. \quad (b) x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j. \quad (c) t_k = \langle u_k, r_0 \rangle / \langle u_k, A u_k \rangle. \quad (d) r_{k+1} \perp r_j$$

para todo $j \leq k$.

P3 (4 pts). Dados $y_1, \dots, y_n \in \mathbb{R}$, encuentre la función constante $f(x) = C$ que mejor aproxima los datos en el sentido de mínimos cuadrados, i.e., que minimiza $\sum_{i=1}^n (y_i - C)^2$. Demuestre que C^* es la media aritmética.

4.4. P1 (Parcial II-2024): Cota $\|\delta x\|/\|x\| \leq \text{cond}(A) \|\delta b\|/\|b\|$

¿Qué mide esta cota? El número de condición amplifica el error *relativo* de los datos ($\|\delta b\|/\|b\|$) al error relativo de la solución ($\|\delta x\|/\|x\|$). Si $\text{cond}(A) = 10^6$ y los datos tienen 8 dígitos correctos, la solución podría tener solo 2.

Estrategia: (1) acotar $\|\delta x\|$ usando que $A\delta x = \delta b$; (2) acotar $\|b\|$ desde abajo usando $b = Ax$; (3) combinar ambas cotas y reconocer $\text{cond}(A)$.

Demostración. Paso 1: acotar $\|\delta x\|$ por arriba.

De $A\hat{x} = b + \delta b$ y $Ax = b$ se resta: $A\delta x = \delta b$, luego $\delta x = A^{-1}\delta b$. Por la propiedad de norma subordinada:

$$\|\delta x\| = \|A^{-1}\delta b\| \leq \|A^{-1}\| \|\delta b\|. \quad (1)$$

Paso 2: acotar $\|b\|$ por abajo.

De $b = Ax$: $\|b\| = \|Ax\| \leq \|A\| \|x\|$. Invirtiendo la desigualdad:

$$\frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}. \quad (2)$$

Paso 3: combinar (1) y (2).

Dividiendo (1) por $\|x\|$ y aplicando (2):

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \|\delta b\| \cdot \frac{1}{\|x\|} \leq \|A^{-1}\| \|\delta b\| \cdot \frac{\|A\|}{\|b\|} = \underbrace{\|A\| \|A^{-1}\|}_{\text{cond}(A)} \frac{\|\delta b\|}{\|b\|}. \quad \square$$

□

Observación: en el Paso 2 usamos una cota *suficientemente fuerte* por abajo para $\|b\|$. Si $\|A\|$ es grande (A “amplifica” los vectores), $\|b\|$ puede ser mucho mayor que $\|x\|$, lo cual hace que el cociente $\|\delta b\|/\|b\|$ sea pequeño... pero $\|A^{-1}\|$ grande (A “también comprime”) compensa. Todo se resume en $\text{cond}(A) = \|A\| \|A^{-1}\|$.

4.5. P2 (Parcial II-2024): Propiedades de Gradientes Conjugados

Contexto: En el algoritmo GC, x_k es la aproximación en el paso k , $r_k = b - Ax_k$ es el residuo, u_k es la dirección de búsqueda A -conjugada, y t_k es el tamaño de paso.

(a) $r_{k+1} = r_k - t_k Au_k$

¿Por qué? El residuo nuevo es la diferencia entre b y A aplicado a la aproximación nueva. Solo hay que expandir.

$$\text{Demostración. } r_{k+1} = b - Ax_{k+1} = b - A(x_k + t_k u_k) = \underbrace{b - Ax_k}_{r_k} - t_k Au_k = r_k - t_k Au_k. \quad \square \quad \square$$

(b) $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$

¿Por qué? En cada paso sumamos $t_j u_j$ al iterado anterior. Acumulando todos los pasos desde x_0 :

Demostración. Por inducción. Base ($k = 0$): $x_1 = x_0 + t_0 u_0$. ✓

Paso: si $x_k = x_0 + \sum_{j=0}^k t_j u_j$, entonces $x_{k+1} = x_k + t_k u_k = x_0 + \sum_{j=0}^k t_j u_j$. □ □

(c) $t_k = \langle u_k, r_0 \rangle / \langle u_k, Au_k \rangle$

¿Por qué? El tamaño de paso se elige como $t_k = \langle u_k, r_k \rangle / \langle u_k, Au_k \rangle$ (minimiza ϕ en dirección u_k). La clave es que $\langle u_k, r_k \rangle = \langle u_k, r_0 \rangle$ porque los residuos intermedios son ortogonales a u_k .

Demostración. De (b): $r_k = b - Ax_k = r_0 - A \sum_{j=0}^k t_j u_j = r_0 - \sum_{j=0}^k t_j Au_j$.

Tomando $\langle u_k, \cdot \rangle$:

$$\langle u_k, r_k \rangle = \langle u_k, r_0 \rangle - \sum_{j=0}^k t_j \underbrace{\langle u_k, Au_j \rangle}_{=0 \text{ (A-conjugados, } j \neq k)} = \langle u_k, r_0 \rangle.$$

Sustituyendo en la fórmula de t_k : $t_k = \langle u_k, r_0 \rangle / \langle u_k, Au_k \rangle$. □

La A -conjugacidad $\langle u_k, Au_j \rangle = 0$ ($j \neq k$) es la propiedad que define las direcciones de búsqueda del GC y es lo que lo hace más eficiente que el Mínimo Descenso. □

(d) $r_{k+1} \perp r_j$ para todo $j \leq k$

¿Por qué? Primero probamos que $r_{k+1} \perp u_i$ para todo $i \leq k$. Luego, como r_j es combinación lineal de $u_0, \dots, u_j$ (con $j \leq k$), la ortogonalidad se hereda.

Demostración. Paso 1: mostrar $\langle r_{k+1}, u_i \rangle = 0$ para $i \leq k$.

De (b): $r_{k+1} = r_0 - \sum_{j=0}^k t_j Au_j$. Tomando $\langle \cdot, u_i \rangle$:

$$\langle r_{k+1}, u_i \rangle = \langle r_0, u_i \rangle - \sum_{j=0}^k t_j \underbrace{\langle Au_j, u_i \rangle}_{=0 \text{ si } j \neq i} = \langle r_0, u_i \rangle - t_i \langle Au_i, u_i \rangle.$$

Usando la definición $t_i = \langle u_i, r_0 \rangle / \langle u_i, Au_i \rangle$:

$$= \langle r_0, u_i \rangle - \frac{\langle u_i, r_0 \rangle}{\langle u_i, Au_i \rangle} \langle Au_i, u_i \rangle = 0.$$

Paso 2: como $\text{span}\{r_0, \dots, r_j\} = \text{span}\{u_0, \dots, u_j\}$, podemos escribir $r_j = \sum_{i=0}^j \alpha_i u_i$ para ciertos escalares α_i . Entonces:

$$\langle r_{k+1}, r_j \rangle = \sum_{i=0}^j \alpha_i \underbrace{\langle r_{k+1}, u_i \rangle}_{=0} = 0. \quad \square$$

□

Resumen de lo que establecen (a)–(d): (a) La recurrencia del residuo. (b) Los iterados son combinaciones de las direcciones de búsqueda. (c) El paso t_k se puede expresar con r_0 en vez de r_k (útil en implementaciones). (d) Los residuos forman una familia ortogonal — esto garantiza que en n pasos el GC converge exactamente (en aritmética exacta).

4.6. P3 (Parcial II-2024): Función constante óptima = media aritmética

Idea: Se trata de un problema de mínimos cuadrados con $A = \mathbf{1} = (1, \dots, 1)^T$ y variable escalar C . La ecuación normal da la media.

Demostración. Sea $E(C) = \sum_{i=1}^n (y_i - C)^2$. Derivando e igualando a cero:

$$\frac{dE}{dC} = -2 \sum_{i=1}^n (y_i - C) = 0 \implies \sum_{i=1}^n y_i = nC \implies C^* = \frac{1}{n} \sum_{i=1}^n y_i.$$

Es mínimo porque $E'' = 2n > 0$. Geométricamente: $A = \mathbf{1}$, ecuación normal $A^T A C = A^T y$, i.e., $nC = \sum y_i$. □

5. Practica: Factorizacion LU (28 May 2026)

5.1. Ejercicio 1: $A = LU$ sin pivoteo

Método: Eliminación de Gauss sin intercambio de filas. El multiplicador $\ell_{ij} = a_{ij}^{(\text{activo})}/a_{jj}^{(\text{activo})}$ anula la entrada (i, j) restando ℓ_{ij} veces la fila pivote. L almacena los multiplicadores; U es la matriz escalonada resultante.

$$A = \begin{pmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{pmatrix}.$$

Columna 1 (pivote $a_{11} = 1$):

$$\ell_{21} = 4/1 = 4: \quad R_2 \leftarrow R_2 - 4R_1 \rightarrow (0, -4, -6).$$

$$\ell_{31} = 4/1 = 4: \quad R_3 \leftarrow R_3 - 4R_1 \rightarrow (0, -2, -4).$$

Columna 2 (pivote $a_{22}^{(2)} = -4$):

$$\ell_{32} = (-2)/(-4) = 1/2: \quad R_3 \leftarrow R_3 - \frac{1}{2}R_2 \rightarrow (0, 0, -1).$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 4 & 1/2 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & 0 & -1 \end{pmatrix}.$$

Verificación: $LU = A$. ✓

5.2. Ejercicio 2: Valores de ξ que impiden LU

Idea: La factorización $A = LU$ (sin pivoteo) existe y es única si y solo si todos los *menores principales* $M_k = \det(A_{1:k, 1:k})$ son no nulos. Si algún $M_k = 0$, el pivote de la columna k sería cero y la eliminación no puede continuar.

Suponiendo $A = \begin{pmatrix} \xi & 1 \\ 1 & \xi \end{pmatrix}$ (u otra matriz con ξ), los menores son:

$$M_1 = \xi, \quad M_2 = \det(A) = \xi^2 - 1 \cdot 1 = \xi^2 - 2.$$

(Ajusta según la matriz concreta del enunciado.) Falla si alguno es cero:

$$M_1 = 0 \Rightarrow \xi = 0; \quad M_2 = 0 \Rightarrow \xi = \pm\sqrt{2}.$$

$A = LU$ sin pivoteo no existe para $\xi \in \{0, \sqrt{2}, -\sqrt{2}\}$.

5.3. Ejercicio 3: Matriz tridiagonal $T = LU$

(a) Verificación: el elemento (i, i) de LU es $(\alpha_{i-1}/\pi_{i-1})\gamma_{i-1} + \pi_i = \beta_i$ por la recurrencia.

(b) Para $\beta = (2, 2, 2, 1)$, $\alpha = \gamma = (-1, -1, -1)$: $\pi_1 = 2$, $\pi_2 = 3/2$, $\pi_3 = 4/3$, $\pi_4 = 1/4$.

$$L = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -1/2 & 1 & 0 & 0 \\ 0 & -2/3 & 1 & 0 \\ 0 & 0 & -3/4 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 2 & -1 & 0 & 0 \\ 0 & 3/2 & -1 & 0 \\ 0 & 0 & 4/3 & -1 \\ 0 & 0 & 0 & 1/4 \end{pmatrix}$$

5.4. Bonus: $PA = LU$ con pivoteo parcial

$$A = \begin{pmatrix} 1 & 2 & 4 & 17 \\ 3 & 6 & -12 & 3 \\ 2 & 3 & -3 & 2 \\ 0 & 2 & -2 & 6 \end{pmatrix}, b = (17, 3, 3, 4)^T.$$

(a) No tiene LU: $M_2 = \det \begin{pmatrix} 1 & 2 \\ 3 & 6 \end{pmatrix} = 0$.

(b) Permutacion $p = (2, 4, 1, 3)$:

$$L = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1/3 & 0 & 1 & 0 \\ 2/3 & -1/2 & 1/2 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 3 & 6 & -12 & 3 \\ 0 & 2 & -2 & 6 \\ 0 & 0 & 8 & 16 \\ 0 & 0 & 0 & -5 \end{pmatrix}$$

(c) $Pb = (3, 4, 17, 3)^T$, sustitucion adelante: $y = (3, 4, 16, -5)^T$, sustitucion atras: $x = (2, -1, 0, 1)^T$.

6. Practica: Factorizacion QR (04 Jun 2026)

6.1. Ejercicio 1: Gram-Schmidt con 3 digitos de punto flotante

$S = \{x_1 = (1, 0, 10^{-3})^T, x_2 = (1, 0, 0)^T, x_3 = (1, 10^{-3}, 0)^T\}$, $fl(\sqrt{2}) = 1,41$.

Paso 1: $\|x_1\| \stackrel{3d}{=} 1,00$. $q_1 = (1,00,0,00,0,001)^T$.

Paso 2: $r_{12} = 1,00$, $v_2 = (0, 0, -0,001)^T$, $\|v_2\| = 0,001$. $q_2 = (0, 0, -1)^T$.

Paso 3: $r_{13} = 1,00$, $r_{23} = 0,00$, $v_3 = (0, 0,001, -0,001)^T$, $\|v_3\| = 1,41 \times 10^{-3}$. $q_3 = (0, 0,709, -0,709)^T$.

6.2. Ejercicio 2: $\|A\|_F = \|R\|_F$

$$\|A\|_F^2 = \text{tr}(A^T A) = \text{tr}(R^T Q^T Q R) = \text{tr}(R^T R) = \|R\|_F^2.$$

6.3. Ejercicio 3: QR y Cholesky de $A^T A$

$$(a) A^T A = \begin{pmatrix} R^T & 0 \end{pmatrix} Q^T Q \begin{pmatrix} R \\ 0 \end{pmatrix} = R^T R = LL^T.$$

(b) Si los diagonales de R son positivos, $R = L^T$ por unicidad de Cholesky.

6.4. Ejercicio 4: Continuacion de Gram-Schmidt

$q_1 = \frac{1}{3}(1, 2, 2)^T$, $q_2 = \frac{1}{\sqrt{18}}(-4, 1, 1)^T$, $a_3 = (3, -1, 1)^T$. $r_{13} = 1$, $r_{23} = -12/\sqrt{18}$. $\hat{q}_3 = a_3 - (3, 0, 0)^T = (0, -1, 1)^T$, $\|\hat{q}_3\| = \sqrt{2}$. $q_3 = (0, -1/\sqrt{2}, 1/\sqrt{2})^T$.

(b) $y = \hat{Q}^T a_3 = (1, -12/\sqrt{18})^T$, $z = \hat{Q}y = (3, 0, 0)^T$, $\hat{q}_3 = a_3 - z = (0, -1, 1)^T$. ✓

7. Ejemplo de clase: QR con Householder (05 Jun 2026)

Recordatorio del método. Para la columna k , el vector de Householder es:

$$u = a_k + \text{sgn}(a_{k1})\|a_k\|e_1, \quad H = I - \underbrace{\frac{2}{u^T u}}_{\rho} uu^T = I - 2\rho uu^T.$$

$Ha_k = -\text{sgn}(a_{k1})\|a_k\|e_1$. Se suma (no resta) para evitar cancelación catastrófica.

$$A = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 3 & 1 \\ -2 & 0 & -1 \end{pmatrix}.$$

Paso 1 — anular entradas (2,1) y (3,1):

$$a_1 = (1, 2, -2)^T, \|a_1\| = \sqrt{1+4+4} = 3, \text{sgn}(a_{11}) = +1.$$

$$u_1 = a_1 + 3e_1 = (4, 2, -2)^T, \quad u_1^T u_1 = 24, \quad \rho = 2/24 = 1/12.$$

$$H_1 = I - \frac{1}{12} \begin{pmatrix} 16 & 8 & -8 \\ 8 & 4 & -4 \\ -8 & -4 & 4 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} -1 & -2 & 2 \\ -2 & 2 & 1 \\ 2 & 1 & 2 \end{pmatrix}.$$

(Verificación columna 1: $H_1 a_1 = (-3, 0, 0)^T = -\|a_1\|e_1$. ✓)

$$A_1 = H_1 A = \begin{pmatrix} -3 & -3 & -3 \\ 0 & 0 & -3 \\ 0 & 3 & 3 \end{pmatrix}.$$

Paso 2 — anular entrada (3,2) en la submatriz 2×2 :

Subvector activo: $\hat{a}_1 = (0, 3)^T$ (columna 2 de A_1 , filas 2-3). $\|\hat{a}_1\| = 3$, $\text{sgn}(\hat{a}_{11}) = 0$ (o +1 por convención).

$$u_2 = (0 + 3, 3)^T = (3, 3)^T, \quad u_2^T u_2 = 18, \quad \rho_2 = 2/18 = 1/9.$$

$$\hat{H}_2 = I_2 - \frac{1}{9} \begin{pmatrix} 9 & 9 \\ 9 & 9 \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ -1 & 0 \end{pmatrix}. \text{ Embebida: } H_2 = \text{diag}(1, \hat{H}_2) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & -1 & 0 \end{pmatrix}.$$

$$R = H_2 A_1 = \begin{pmatrix} -3 & -3 & -3 \\ 0 & -3 & -3 \\ 0 & 0 & 3 \end{pmatrix}, \quad Q = H_1 H_2 = \frac{1}{3} \begin{pmatrix} -1 & -2 & 2 \\ -2 & -1 & -2 \\ 2 & -2 & -1 \end{pmatrix}.$$

Verificación: $QR = A$ y $Q^T Q = I$. ✓

8. Cholesky por bloques (Quiz 1 — 2024-II)

Quiz 1 2024-II — Factorización de Cholesky por Bloques

P1. Sea $B = \begin{pmatrix} A & a \\ a^T & \alpha \end{pmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}$ simétrica definida positiva, donde $A \in \mathbb{R}^{n \times n}$ es SPD con factorización de Cholesky $A = LL^T$ ya conocida. Encuentre la factorización de Cholesky $B = L_B L_B^T$ en términos de L , a y α . Use el resultado para describir cómo resolver $Bx = c$.

Idea: buscar $L_B = \begin{pmatrix} L & 0 \\ \ell^T & \beta \end{pmatrix}$ (triangular inferior por bloques) tal que $L_B L_B^T = B$. Igualando bloque a bloque se determinan ℓ y β .

Derivación de ℓ y β : expandiendo $L_B L_B^T$:

$$L_B L_B^T = \begin{pmatrix} L & 0 \\ \ell^T & \beta \end{pmatrix} \begin{pmatrix} L^T & \ell \\ 0 & \beta \end{pmatrix} = \begin{pmatrix} LL^T & L\ell \\ \ell^T L^T & \ell^T \ell + \beta^2 \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} A & a \\ a^T & \alpha \end{pmatrix}.$$

Igualando bloque a bloque:

- Bloque (1, 1): $LL^T = A$ ✓ (ya estaba factorizada).
- Bloque (1, 2): $L\ell = a \Rightarrow$ resolver el sistema triangular $L\ell = a$ (sustitución adelante).
- Bloque (2, 2): $\ell^T\ell + \beta^2 = \alpha \Rightarrow \beta = \sqrt{\alpha - \|\ell\|^2}$.

$$L_B = \begin{pmatrix} L & 0 \\ \ell^T & \beta \end{pmatrix}, \quad L\ell = a, \quad \beta = \sqrt{\alpha - \ell^T\ell}.$$

Test SPD: el algoritmo falla si $\alpha - \ell^T\ell \leq 0$, lo que significa que B no es SPD.

Resolver $Bx = c$ con la factorización: con $L_B L_B^T x = c$ y $x = (\tilde{x}, x_{n+1})^T$, $c = (\tilde{c}, c_{n+1})^T$:

Sustitución adelante ($L_B y = c$):

$$L\tilde{y} = \tilde{c} \Rightarrow \tilde{y} = L^{-1}\tilde{c} \quad (\text{sustitución adelante en } n \text{ ecuaciones})$$

$$\beta y_{n+1} = c_{n+1} - \ell^T \tilde{y} \Rightarrow y_{n+1} = \frac{c_{n+1} - \ell^T \tilde{y}}{\beta}.$$

Sustitución atrás ($L_B^T x = y$):

$$\beta x_{n+1} = y_{n+1} \Rightarrow x_{n+1} = \frac{y_{n+1}}{\beta}.$$

$$L^T \tilde{x} = \tilde{y} - x_{n+1} \ell \Rightarrow \tilde{x} = L^{-T}(\tilde{y} - x_{n+1} \ell) \quad (\text{sustitución atrás}).$$

9. Demostraciones adicionales de practica

9.1. Algoritmo de Cholesky 3×3

Idea: Para A SPD se busca L triangular inferior tal que $A = LL^T$. Igualando entrada por entrada (columna a columna):

Columna 1 ($j = 1$): el elemento diagonal se obtiene de $a_{11} = \ell_{11}^2$, los de abajo de $a_{i1} = \ell_{i1}\ell_{11}$:

$$\ell_{11} = \sqrt{a_{11}}, \quad \ell_{21} = \frac{a_{21}}{\ell_{11}}, \quad \ell_{31} = \frac{a_{31}}{\ell_{11}}.$$

Columna 2 ($j = 2$): el diagonal de $a_{22} = \ell_{21}^2 + \ell_{22}^2$, el subdiagonal de $a_{32} = \ell_{31}\ell_{21} + \ell_{32}\ell_{22}$:

$$\ell_{22} = \sqrt{a_{22} - \ell_{21}^2}, \quad \ell_{32} = \frac{a_{32} - \ell_{31}\ell_{21}}{\ell_{22}}.$$

Columna 3 ($j = 3$): diagonal de $a_{33} = \ell_{31}^2 + \ell_{32}^2 + \ell_{33}^2$:

$$\ell_{33} = \sqrt{a_{33} - \ell_{31}^2 - \ell_{32}^2}.$$

Patrón general (columna j , filas $i \geq j$):

$$\ell_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} \ell_{jk}^2}, \quad \ell_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} \ell_{ik}\ell_{jk}}{\ell_{jj}} \quad (i > j).$$

9.2. Escalar optimo $\alpha = \arg \min \|b - \alpha a\|_2$

Ecuaciones normales: $a^T a \alpha = a^T b \Rightarrow \alpha = a^T b / a^T a$.

9.3. Producto de triangulares inferiores es triangular inferior

Para $i < j$: si $k \leq i$, entonces $(L_2)_{kj} = 0$; si $k > i$, entonces $(L_1)_{ik} = 0$. Ambos casos anulan el sumando. Diagonal: $(L_1)_{ii}(L_2)_{ii} = 1$.

9.4. Unicidad de la factorizacion LU

Idea: Si hubiera dos factorizaciones, su cociente sería simultáneamente triangular inferior Y superior, forzando que sea diagonal. Con los unos en la diagonal de L , la única opción es la identidad.

Demostración. Suponer $L_1 U_1 = A = L_2 U_2$ con L_i unidad-triangulares inferiores y U_i triangulares superiores con diagonal no nula.

Despejando: $L_2^{-1} L_1 = U_2 U_1^{-1}$.

- **Izquierda:** $L_2^{-1} L_1$ es triangular inferior (producto de inferiores).
- **Derecha:** $U_2 U_1^{-1}$ es triangular superior (producto de superiores).

Una matriz que es a la vez triangular inferior y superior es **diagonal**. Como L_1, L_2 tienen unos en la diagonal, $L_2^{-1} L_1$ también; por tanto $L_2^{-1} L_1 = I$, i.e. $L_1 = L_2$ y $U_1 = U_2$. □ □

9.5. Sistemas transpuestos con $PA = LU$

Resolver $x^T A^T = b$ (equivale a $Ax = b^T$): $Ly = Pb^T$ (adelante), $Ux = y$ (atras).

Resolver $x^T A = b$ (equivale a $A^T x = b^T$, con $A^T = U^T L^T P$):

1. $U^T z = b^T$ (adelante, U^T triangular inferior).
2. $L^T w = z$ (atras, L^T triangular superior).
3. $x = P^T w$.

9.6. Propiedades del proceso de Gram-Schmidt

$$Q_j Q_j^T = \sum_{i=1}^j q_i q_i^T: Q_j Q_j^T = [q_1 | \cdots | q_j] \begin{pmatrix} q_1^T \\ \vdots \\ q_j^T \end{pmatrix} = \sum_{i=1}^j q_i q_i^T.$$

$$\hat{q}_j = (I - Q_{j-1} Q_{j-1}^T) a_j: \hat{q}_j = a_j - \sum_{i < j} \langle q_i, a_j \rangle q_i = a_j - \left(\sum_{i < j} q_i q_i^T \right) a_j = (I - Q_{j-1} Q_{j-1}^T) a_j.$$

10. Parcial 2 — Cálculo Científico I (I-2025)

Parcial 2 I-2025 (27 Jun 2025) — P1: 6 pts, P2: 7 pts, P3: 7 pts

P1 (6 pts). (a) Describa el algoritmo para calcular la descomposición SVD de $A \in \mathbb{R}^{m \times n}$. Justifique por qué los vectores $u_i = Av_i/\sigma_i$ son ortonormales. (b) Calcule la SVD de $A =$

$$\begin{pmatrix} -2 & 11 \\ -10 & 5 \\ 1 & 0 \end{pmatrix}.$$

P2 (7 pts). Dado $A = L + D + U$ con D diagonal, L estrictamente inferior y U estrictamente superior, considere el **Algoritmo 1**:

- Paso 0: resolver $(D + L)y = b$.
- Paso k : calcular $w_k = -Ux_k$; resolver $(D + L)z_k = w_k$; actualizar $x_{k+1} = z_k + y$.

(a) Identifique la matriz B y el vector d de la iteración $x_{k+1} = Bx_k + d$. ¿Qué método clásico es éste? (b) Demuestre que si $\|B\| < 1$, el algoritmo converge para cualquier $x^{(0)}$.

P3 (7 pts). Sea A simétrica definida positiva y $r_k = b - Ax_k$ el residuo en el paso k . Se aplica un método de la forma $x_{k+1} = x_k + t_k p_k$. (a) Si $p_k = r_k$ (Mínimo Descenso) con $t_k = \langle r_k, r_k \rangle / \langle r_k, Ar_k \rangle$, demuestre que $r_{k+1} \perp r_k$. (b) Si $p_k = u_k$ (Gradientes Conjugados) con las u_k A -conjugadas, demuestre que $r_{k+1} \perp r_j$ para todo $j \leq k$.

10.1. P1(a): Algoritmo para hallar la SVD de $A \in \mathbb{R}^{m \times n}$

1. **Formar** $C = A^T A \in \mathbb{R}^{n \times n}$ (simétrica, semidefinida positiva).
2. **Calcular** los autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ de C .
3. **Valores singulares:** $\sigma_i = \sqrt{\lambda_i}$; armar $\Sigma \in \mathbb{R}^{m \times n}$ con $\Sigma_{ii} = \sigma_i$, resto cero.
4. **Vectores singulares derechos:** autovectores ortonormales v_i de C ; armar $V = [v_1 | \dots | v_n] \in \mathbb{R}^{n \times n}$.
5. **Vectores singulares izquierdos:** $u_i = Av_i/\sigma_i$ para $\sigma_i > 0$; completar hasta base ortonormal de $\mathbb{R}^m \Rightarrow U \in \mathbb{R}^{m \times m}$.
6. $A = U\Sigma V^T$.

Por qué los u_i son ortonormales: $\langle u_i, u_j \rangle = \frac{v_i^T A^T A v_j}{\sigma_i \sigma_j} = \frac{\lambda_j v_i^T v_j}{\sigma_i \sigma_j} = \delta_{ij}$.

10.2. P1(b): SVD de $A = \begin{pmatrix} -2 & 11 \\ -10 & 5 \\ 1 & 0 \end{pmatrix}$

Paso 1 — $A^T A$:

$$A^T A = \begin{pmatrix} -2 & -10 & 1 \\ 11 & 5 & 0 \end{pmatrix} \begin{pmatrix} -2 & 11 \\ -10 & 5 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 4 + 100 + 1 & -22 - 50 \\ -22 - 50 & 121 + 25 \end{pmatrix} = \begin{pmatrix} 105 & -72 \\ -72 & 146 \end{pmatrix}.$$

Paso 2 — Autovalores:

$$\det(A^T A - \lambda I) = \lambda^2 - 251\lambda + (105 \cdot 146 - 72^2) = \lambda^2 - 251\lambda + 10146 = 0.$$

$$\lambda = \frac{251 \pm \sqrt{251^2 - 4 \cdot 10146}}{2} = \frac{251 \pm \sqrt{22417}}{2}. \quad \lambda_1 \approx 200,36, \quad \lambda_2 \approx 50,64.$$

Verificación: $\lambda_1 + \lambda_2 = 251 = \|A\|_F^2 = 4 + 121 + 100 + 25 + 1$. ✓

Paso 3 — Valores singulares: $\sigma_1 \approx 14,15$, $\sigma_2 \approx 7,12$.

Paso 4 — Vectores singulares derechos:

Para λ_1 : $(A^T A - \lambda_1 I)v = 0 \Rightarrow \begin{pmatrix} -95,36 & -72 \\ -72 & -54,36 \end{pmatrix} v = 0 \Rightarrow v_{11} \approx -0,755 v_{12}$. Normalizando: $v_1 \approx (-0,603, 0,798)^T$.

Para λ_2 : $v_2 \approx (0,798, 0,603)^T$. Ort.: $v_1^T v_2 \approx 0$. ✓

$$V \approx \begin{pmatrix} -0,603 & 0,798 \\ 0,798 & 0,603 \end{pmatrix}.$$

Paso 5 — Vectores singulares izquierdos:

$$u_1 = \frac{Av_1}{\sigma_1} \approx \frac{1}{14,15} \begin{pmatrix} 9,985 \\ 10,016 \\ -0,603 \end{pmatrix} \approx \begin{pmatrix} 0,706 \\ 0,708 \\ -0,043 \end{pmatrix}, \quad u_2 = \frac{Av_2}{\sigma_2} \approx \frac{1}{7,12} \begin{pmatrix} 5,031 \\ -4,969 \\ 0,798 \end{pmatrix} \approx \begin{pmatrix} 0,707 \\ -0,698 \\ 0,112 \end{pmatrix}.$$

$u_3 = u_1 \times u_2 \approx (0,050, -0,109, -0,993)^T$ (producto vectorial).

$$A \approx \underbrace{\begin{pmatrix} 0,706 & 0,707 & 0,050 \\ 0,708 & -0,698 & -0,109 \\ -0,043 & 0,112 & -0,993 \end{pmatrix}}_U \underbrace{\begin{pmatrix} 14,15 & 0 \\ 0 & 7,12 \\ 0 & 0 \end{pmatrix}}_\Sigma \underbrace{\begin{pmatrix} -0,603 & 0,798 \\ 0,798 & 0,603 \end{pmatrix}}_{V^T}.$$

10.3. P2(a): Identificar B y d del método estacionario (Algoritmo 1)

El enunciado da $A = L + D + U$ (L estrictamente inferior, D diagonal, U estrictamente superior) y el algoritmo:

1. Resolver $(D + L)y = b$ (una sola vez, sustitución adelante).
2. Para $k = 0, 1, \dots$: $w_k = -Ux_k$; resolver $(D + L)z_k = w_k$; $x_{k+1} = z_k + y$.

Sustituyendo $z_k = -(D + L)^{-1}Ux_k$ y $y = (D + L)^{-1}b$:

$$x_{k+1} = -(D + L)^{-1}Ux_k + (D + L)^{-1}b = Bx_k + d.$$

Este es el **método de Gauss-Seidel**:

$$B = T_{GS} = -(D + L)^{-1}U, \quad d = (D + L)^{-1}b.$$

10.4. P2(b): Convergencia cuando $\|B\| < 1$

Idea: el error satisface $e^{(k)} = Be^{(k-1)}$, así que crece por un factor $\|B\| < 1$ en cada paso y decae a cero.

Demostración. Sea x^* el punto fijo: $x^* = Bx^* + d$. Restando de la iteración $x_{k+1} = Bx_k + d$:

$$e^{(k+1)} = x^{(k+1)} - x^* = B(x^{(k)} - x^*) = Be^{(k)}.$$

Por inducción $e^{(k)} = B^k e^{(0)}$, luego:

$$\|e^{(k)}\| \leq \|B^k\| \|e^{(0)}\| \leq \|B\|^k \|e^{(0)}\| \xrightarrow[k \rightarrow \infty]{\|B\| < 1} 0.$$

El método converge para cualquier $x^{(0)}$. Nota: la condición $\|B\| < 1$ es *suficiente*; la condición necesaria y suficiente es $\rho(B) < 1$ (radio espectral). □ □

10.5. P3(a): $r_{k+1} \perp r_k$ en Mínimo Descenso ($p_k = r_k$)

Idea: el paso t_k se elige exactamente para minimizar $f(x_k + t_k r_k)$ a lo largo de la dirección r_k ; la condición de mínimo dice que el gradiente en x_{k+1} , que es $-r_{k+1}$, debe ser perpendicular a la dirección de búsqueda r_k .

Demostración. Calculamos el nuevo residuo usando $x_{k+1} = x_k + t_k r_k$:

$$r_{k+1} = b - Ax_{k+1} = b - A(x_k + t_k r_k) = r_k - t_k A r_k.$$

Tomamos el producto interno con r_k :

$$\langle r_{k+1}, r_k \rangle = \langle r_k, r_k \rangle - t_k \langle A r_k, r_k \rangle = \langle r_k, r_k \rangle - \frac{\langle r_k, r_k \rangle}{\langle r_k, A r_k \rangle} \langle A r_k, r_k \rangle = 0. \quad \square$$

La cancelación ocurre porque t_k fue diseñado para que el numerador y el denominador se cancelen. $\square$

10.6. P3(b): $r_{k+1} \perp r_j$ para todo $j \leq k$ en Gradientes Conjugados ($p_k = u_k$)

Demostración. Las direcciones $\{u_k\}$ son A -conjugadas: $\langle u_i, A u_j \rangle = 0$ para $i \neq j$. El tamaño de paso es $t_k = \langle u_k, r_0 \rangle / \langle u_k, A u_k \rangle$ (demostrado en §4.5 parte (c)). De la propiedad (b): $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$, luego

$$r_{k+1} = r_0 - \sum_{j=0}^k t_j A u_j.$$

Para cualquier $i \leq k$:

$$\langle r_{k+1}, u_i \rangle = \langle r_0, u_i \rangle - \sum_{j=0}^k t_j \underbrace{\langle A u_j, u_i \rangle}_{=0 \text{ si } j \neq i} = \langle r_0, u_i \rangle - t_i \langle A u_i, u_i \rangle = \langle r_0, u_i \rangle - \frac{\langle u_i, r_0 \rangle}{\langle u_i, A u_i \rangle} \langle A u_i, u_i \rangle = 0.$$

Como $\text{span}\{r_0, \dots, r_k\} = \text{span}\{u_0, \dots, u_k\}$, cualquier $r_j = \sum_i \alpha_i u_i$ con $i \leq k$:

$$\langle r_{k+1}, r_j \rangle = \sum_i \alpha_i \underbrace{\langle r_{k+1}, u_i \rangle}_{=0} = 0. \quad \square$$

$\square$

11. Ejercicios de Pizarrón

11.1. Matrices de Hessenberg: LU y algoritmo eficiente

Una matriz **superior de Hessenberg** satisface $a_{ij} = 0$ para $i > j + 1$ (ceros debajo de la primera subdiagonal).

11.1.1. Cálculo de LU para A de Hessenberg

$$A = \begin{pmatrix} 4 & 2 & 3 \\ -2 & 1 & -2 \\ 0 & 1 & 2 \end{pmatrix}.$$

Paso 1: único multiplicador $m_{21} = -2/4 = -1/2$; fila 3 no cambia ($a_{31} = 0$):

$$R_2 \leftarrow R_2 + \frac{1}{2} R_1 \Rightarrow (0, 2, -\frac{1}{2}).$$

Paso 2: único multiplicador $m_{32} = 1/2$:

$$R_3 \leftarrow R_3 - \frac{1}{2}R_2^{(1)} \Rightarrow (0, 0, 2 + \frac{1}{4}) = (0, 0, \frac{9}{4}).$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ 0 & \frac{1}{2} & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 4 & 2 & 3 \\ 0 & 2 & -\frac{1}{2} \\ 0 & 0 & \frac{9}{4} \end{pmatrix}.$$

Verificación: $LU = \begin{pmatrix} 4 & 2 & 3 \\ -2 & 1 & -2 \\ 0 & 1 & 2 \end{pmatrix} = A. \checkmark$

11.1.2. Algoritmo eficiente GaussH

En cada paso k de la eliminación gaussiana en una matriz de Hessenberg, solo hay *un* multiplicador ($m_{k+1,k}$), porque la columna k ya tiene ceros en las posiciones $k+2, \dots, n$.

Rutina GaussH

Para $k = 1, \dots, n-1$:

1. $m_{k+1,k} = A_{k+1,k}/A_{kk}$
2. $A_{k+1,k+1:n} \leftarrow A_{k+1,k+1:n} - m_{k+1,k} \cdot A_{k,k+1:n}$

Número de operaciones: $(n-1)$ divisiones + $\sum_{k=1}^{n-1} 2(n-k) = (n-1)n \approx n^2$ operaciones aritméticas. **Costo $O(n^2)$ vs. $O(n^3/3)$ de Gauss estándar.**

11.2. Demostración: $Q^T L$ es triangular superior

Demostración. Sea $A \in \mathbb{R}^{n \times n}$ no singular con factorizaciones $A = LU$ y $A = QR$.

Aplicando Q^T a la izquierda en $A = QR$:

$$Q^T A = R \quad (\text{triangular superior}).$$

Sustituyendo $A = LU$:

$$Q^T(LU) = R \implies (Q^T L)U = R \implies Q^T L = RU^{-1}.$$

R es triangular superior y U^{-1} es triangular superior (la inversa de una triangular superior es triangular superior), por lo tanto RU^{-1} es triangular superior.

Luego $Q^T L$ es triangular superior. □ □

12. Propiedades completas de la matriz de Householder

Sea $H = I - 2 \frac{vv^T}{v^T v}$, $v \in \mathbb{R}^n$, $v \neq 0$.

Las propiedades P1 y P2 aparecen en contexto de examen en §2.1; aquí se presentan todas con demostraciones completas.

12.1. P1. H es simétrica ($H^T = H$)

Demostración. $H^T = \left(I - \frac{2vv^T}{v^T v} \right)^T = I - \frac{2(vv^T)^T}{v^T v} = I - \frac{2vv^T}{v^T v} = H.$ □ □

12.2. P2. H es ortogonal ($H^T H = I$, equivalentemente $H^2 = I$)

Demostración.

$$H^2 = \left(I - \frac{2vv^T}{v^T v} \right)^2 = I - \frac{4vv^T}{v^T v} + \frac{4v(v^T v)v^T}{(v^T v)^2} = I - \frac{4vv^T}{v^T v} + \frac{4vv^T}{v^T v} = I.$$

Como P1 da $H^T = H$: $H^T H = H^2 = I$, es decir H es ortogonal. □ □

12.3. P3. H es involutoria ($H^{-1} = H$)

Demostración. De $H^2 = I$ se sigue directamente $H^{-1} = H$. □ □

12.4. P4. $\det(H) = -1$

Demostración. Por el lema del determinante de rango 1: $\det(I + ab^T) = 1 + b^T a$. Tomando $a = -2v/(v^T v)$ y $b = v$:

$$\det(H) = 1 + v^T \left(-\frac{2v}{v^T v} \right) = 1 - \frac{2v^T v}{v^T v} = 1 - 2 = -1. \quad \square$$

□

12.5. P5. $Hv = -v$

Demostración. $Hv = v - \frac{2v(v^T v)}{v^T v} = v - 2v = -v$. □ □

12.6. P6. $Hx = x$ para todo $x \perp v$

Demostración. Si $v^T x = 0$: $Hx = x - \frac{2v(v^T x)}{v^T v} = x - 0 = x$. □ □

Interpretación geométrica: H es la *reflexión* respecto al hiperplano $v^\perp = \{x : v^T x = 0\}$. Los vectores en $v^\perp$ son fijos (P6); el vector v se invierte (P5).

12.7. P7. Los autovalores de H son 1 (multiplicidad $n - 1$) y -1 (multiplicidad 1)

Demostración. El subespacio $v^\perp$ tiene dimensión $n - 1$; por P6, todo $x \in v^\perp$ cumple $Hx = x$, luego 1 es autovalor de multiplicidad $\geq n - 1$. Por P5, $Hv = -v$, así que -1 es autovalor con autovector v . Los autoespacios $v^\perp$ y $\text{span}\{v\}$ son ortogonales y su dimensión suma n , por lo que no existen más autovalores. □ □

Consecuencia de P4: $\det(H) = 1^{n-1} \cdot (-1)^1 = -1$. ✓

12.8. P8. Preservación de la norma: $\|Hx\|_2 = \|x\|_2$

Demostración. $\|Hx\|_2^2 = (Hx)^T (Hx) = x^T H^T H x = x^T x = \|x\|_2^2$ (pues $H^T H = I$). □ □

12.9. P9. Propiedad de aniquilación (construcción para la factorización QR)

Dado $a \in \mathbb{R}^n$, se elige $v = a + \text{sign}(a_1)\|a\|_2 e_1$ para introducir ceros en las posiciones $2, \dots, n$.

Demostración. Calculamos $v^T v$ y $v^T a$ con el v elegido:

$$\begin{aligned} v^T v &= \|a\|_2^2 + 2 \operatorname{sign}(a_1) \|a\|_2 a_1 + \|a\|_2^2 = 2\|a\|_2 (\|a\|_2 + |a_1|). \\ v^T a &= \|a\|_2^2 + \operatorname{sign}(a_1) \|a\|_2 a_1 = \|a\|_2 (\|a\|_2 + |a_1|). \end{aligned}$$

Entonces:

$$Ha = a - \frac{2v(v^T a)}{v^T v} = a - \frac{2v\|a\|_2(\|a\|_2 + |a_1|)}{2\|a\|_2(\|a\|_2 + |a_1|)} = a - v = -\operatorname{sign}(a_1) \|a\|_2 e_1. \quad \square$$

□

Elección del signo: usar $\operatorname{sign}(a_1)$ (igual al signo de a_1) garantiza $v_1 = a_1 + \operatorname{sign}(a_1)\|a\| \approx 2|a_1|$, evitando *cancelación catastrófica* cuando $a_1 \approx \|a\|$.

13. Práctica: LSP y Métodos Iterativos Estacionarios (11 Jun 2026)

Práctica: LSP y Métodos Iterativos Estacionarios (11 Jun 2026)

LSP 1. Una empresa registró ventas (miles USD) en sus primeros 3 años: $(1, 7), (2, 4), (3, 3)$. Ajuste un modelo lineal $\widehat{\text{ventas}}(t) = a + bt$ por mínimos cuadrados. ¿En qué momento la empresa comenzaría a perder dinero (ventas ≤ 0) según el modelo?

LSP 2. Dado un vector $x \in \mathbb{R}^m$ y datos $y \in \mathbb{R}^m$, encuentre el escalar $\hat{\alpha}$ que minimiza $\|y - \alpha x\|_2$.

Iter. 1. Sea $A = \begin{pmatrix} -10 & 2 \\ \beta & 5 \end{pmatrix}$. Determine para qué valores de β convergen (a) el método de Jacobi, (b) el método de Gauss-Seidel. Calcule el radio espectral de las matrices de iteración T_J y T_{GS} en función de β .

Iter. 2. Dado el método de Richardson $x_{k+1} = x_k + \alpha(b - Ax_k)$, identifique la matriz de iteración B y el vector constante d . Para A SPD con autovalores $0 < \lambda_{\min} \leq \dots \leq \lambda_{\max}$, determine los valores de α para los cuales converge.

13.1. LSP 1: Predicción por regresión lineal

Datos (año, ventas en miles USD): $(1, 7), (2, 4), (3, 3)$. Modelo lineal: $\text{ventas}(t) = a + bt$.

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \quad b_{\text{datos}} = \begin{pmatrix} 7 \\ 4 \\ 3 \end{pmatrix}.$$

Ecuaciones normales $A^T A \begin{pmatrix} a \\ b \end{pmatrix} = A^T b_{\text{datos}}$:

$$A^T A = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}, \quad A^T b_{\text{datos}} = \begin{pmatrix} 14 \\ 24 \end{pmatrix}.$$

Reducción por filas: $R_2 \leftarrow R_2 - 2R_1 \Rightarrow 2\hat{b} = -4 \Rightarrow \hat{b} = -2$; luego $3\hat{a} = 14 - 6(-2) = 26 \Rightarrow \hat{a} = 26/3$.

Modelo ajustado: $\widehat{\text{ventas}}(t) = \frac{26}{3} - 2t$.

Igualando a cero: $t^* = 13/3 \approx 4,33$ años desde el inicio. La fracción de año es $\frac{1}{3} \times 12 \approx 4$ meses.

La empresa comienza a perder dinero al **cuarto mes del año 4**.

13.2. LSP 2: Escalar α que minimiza $\|y - \alpha x\|_2$

Ver §9.2: $\hat{\alpha} = x^T y / (x^T x)$.

13.3. Iter. 1: Condición sobre β para la matriz $A = \begin{pmatrix} -10 & 2 \\ \beta & 5 \end{pmatrix}$

Con $D = \text{diag}(-10, 5)$, $L_s = \begin{bmatrix} 0 & 0 \\ \beta & 0 \end{bmatrix}$, $U_s = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}$:

$$T_J = -D^{-1}(L_s + U_s) = \begin{pmatrix} 0 & 1/5 \\ -\beta/5 & 0 \end{pmatrix}.$$

$$\det(T_J - \lambda I) = \lambda^2 + \beta/25 = 0 \Rightarrow \rho(T_J) = \sqrt{|\beta|/25}.$$

$$T_{GS} = -(D + L_s)^{-1}U_s = \begin{pmatrix} 0 & 1/5 \\ 0 & -\beta/25 \end{pmatrix}.$$

Autovalores 0 y $-\beta/25$; luego $\rho(T_{GS}) = |\beta|/25$.

Condición necesaria y suficiente (ambos métodos): $|\beta| < 25$. **Condición suficiente EDD (fila 2):** $|5| > |\beta|$, i.e. $|\beta| < 5$.

13.4. Iter. 2: Matriz de iteración — método de Richardson

$$x_{k+1} = x_k + \alpha(b - Ax_k) = (I - \alpha A)x_k + \alpha b.$$

Matriz de iteración: $B = I - \alpha A$. Vector constante: $d = \alpha b$.
Si A es SPD con $0 < \lambda_{\min} \leq \dots \leq \lambda_{\max}$: $\rho(B) < 1 \iff 0 < \alpha < 2/\lambda_{\max}$.

13.5. Pseudocódigo de Gauss-Seidel para n variables

En la iteración $k+1$, la variable x_i se actualiza usando los valores *ya calculados* en la misma iteración ($j < i$) y los *anteriores* ($j > i$):

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 1, \dots, n.$$

Pseudocódigo Gauss-Seidel (n variables)

Entrada: $A \in \mathbb{R}^{n \times n}$, b , $x^{(0)}$, tolerancia ε , $k_{\max}$.

Para $k = 0, 1, \dots, k_{\max}$:

Para $i = 1, \dots, n$: $x_i^{(k+1)} \leftarrow \frac{b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)}}{a_{ii}}$

Si $\|x^{(k+1)} - x^{(k)}\|_{\infty} < \varepsilon$: **parar**.

Salida: $x^{(k+1)}$ (aproximación de la solución).

Diferencia con Jacobi: Jacobi usa exclusivamente $x_j^{(k)}$ para todos los j ; Gauss-Seidel incorpora $x_j^{(k+1)}$ en cuanto lo calcula ($j < i$), lo que suele acelerar la convergencia.

14. Práctica: Gradientes Conjugados (18 Jun 2026)

Práctica: Gradientes Conjugados (18 Jun 2026)

GC 1. Identifique la matriz A , el vector b y la constante c en la función cuadrática $q(x) = 3x_1^2 - 2x_1x_2 + x_1x_3 - x_3^2 + x_3 - x_1 + 5$ escrita en la forma estándar $q(x) = \frac{1}{2}x^T Ax - b^T x + c$.

GC 2. Sea A SPD y $r_k = b - Ax_k$ el residuo en el paso k del método de Mínimo Descenso ($x_{k+1} = x_k + t_k r_k$, $t_k = \langle r_k, r_k \rangle / \langle r_k, Ar_k \rangle$). Demuestre que $r_{k+1} \perp r_k$.

GC 3. Sean $\{r_k\}$ residuos y $\{u_k\}$ direcciones de búsqueda del método de Gradientes Conjugados. Demuestre: (a) $r_{k+1} = r_k - t_k Au_k$. (b) $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$. (c) $t_k = \langle u_k, r_0 \rangle / \langle u_k, Au_k \rangle$.

GC 4. Demuestre las formas alternativas: $t_k = \langle r_k, r_k \rangle / \langle u_k, Au_k \rangle$ y $\beta_k = -\langle r_{k+1}, r_{k+1} \rangle / \langle r_k, r_k \rangle$, donde β_k es el coeficiente de la actualización $u_{k+1} = r_{k+1} + \beta_k u_k$ (o equivalentemente $u_{k+1} = r_{k+1} - \beta_k u_k$ según la convención del algoritmo).

14.1. GC 1: Identificar A , b , c en $q(x)$

$$q(x) = 3x_1^2 - 2x_1x_2 + x_1x_3 - x_3^2 + x_3 - x_1 + 5.$$

Forma estándar: $q(x) = \frac{1}{2}x^T Ax - b^T x + c$.

Parte cuadrática ($\frac{1}{2}x^T Ax$): el coeficiente de x_i^2 es $a_{ii}/2$; el coeficiente de $x_i x_j$ ($i \neq j$) es a_{ij} (por simetría):

$$a_{11}/2 = 3, \quad a_{22}/2 = 0, \quad a_{33}/2 = -1; \quad a_{12} = -2, \quad a_{13} = 1, \quad a_{23} = 0.$$

$$A = \begin{pmatrix} 6 & -2 & 1 \\ -2 & 0 & 0 \\ 1 & 0 & -2 \end{pmatrix}.$$

Verificación: $\frac{1}{2}x^T Ax = 3x_1^2 - 2x_1x_2 + x_1x_3 - x_3^2$. ✓

Parte lineal ($-b^T x = -x_1 + x_3$): $b = (1, 0, -1)^T$.

Constante: $c = 5$.

$$A = \begin{pmatrix} 6 & -2 & 1 \\ -2 & 0 & 0 \\ 1 & 0 & -2 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \quad c = 5.$$

14.2. GC 2: $r_{k+1} \perp r_k$ en Mínimo Descenso

Demostración completa en §4.2. Transcripción de la solución oficial:

Demostración. $r_{k+1} = b - A(x_k + t_k r_k) = r_k - t_k Ar_k$.

$$\langle r_{k+1}, r_k \rangle = \langle r_k, r_k \rangle - t_k \langle Ar_k, r_k \rangle = \langle r_k, r_k \rangle - \frac{\langle r_k, r_k \rangle}{\langle r_k, Ar_k \rangle} \langle Ar_k, r_k \rangle = 0. \quad \square$$

□

14.3. GC 3: Propiedades del Gradiente Conjugado (a)–(c)

Estas propiedades son centrales para entender por qué el GC funciona. Las probamos directamente desde la definición del algoritmo.

(a) $r_{k+1} = r_k - t_k Au_k$

Demostración. $r_{k+1} = b - Ax_{k+1} = b - A(x_k + t_k u_k) = (b - Ax_k) - t_k Au_k = r_k - t_k Au_k$. □ □

(b) $x_{k+1} = x_0 + \sum_{j=0}^k t_j u_j$

Demostración. Por inducción. Base: $x_1 = x_0 + t_0 u_0$ (definición del algoritmo).

Paso: suponiendo $x_k = x_0 + \sum_{j=0}^{k-1} t_j u_j$, entonces $x_{k+1} = x_k + t_k u_k = x_0 + \sum_{j=0}^k t_j u_j$. □ □

(c) $t_k = \langle u_k, r_0 \rangle / \langle u_k, Au_k \rangle$

Idea: la dirección de búsqueda u_k y el residuo inicial r_0 tienen el mismo producto interno que u_k y el residuo actual r_k , porque los residuos intermedios son ortogonales a u_k .

Demostración. De (b): $x_k = x_0 + \sum_{j < k} t_j u_j$, luego $r_k = r_0 - \sum_{j < k} t_j Au_j$.

Tomando producto interno con u_k :

$$\langle u_k, r_k \rangle = \langle u_k, r_0 \rangle - \sum_{j < k} t_j \underbrace{\langle u_k, Au_j \rangle}_{=0 \text{ (} j \neq k, A\text{-conj.)}} = \langle u_k, r_0 \rangle.$$

Pero la fórmula del algoritmo es $t_k = \langle u_k, r_k \rangle / \langle u_k, Au_k \rangle$ (el paso óptimo para minimizar ϕ en dirección u_k). Sustituyendo: $t_k = \langle u_k, r_0 \rangle / \langle u_k, Au_k \rangle$. □ □

14.4. GC 4: Formas alternativas de t_k y β_k

El algoritmo GC define $\beta_k = \langle r_{k+1}, Au_k \rangle / \langle u_k, Au_k \rangle$ y $u_{k+1} = r_{k+1} - \beta_k u_k$.

Se demuestran las expresiones equivalentes:

$$t_k = \frac{\langle r_k, r_k \rangle}{\langle u_k, Au_k \rangle}, \quad \beta_k = -\frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle}.$$

$t_k = \langle r_k, r_k \rangle / \langle u_k, Au_k \rangle$. **Caso $k = 0$:** $u_0 = r_0$, luego $\langle u_0, r_0 \rangle = \langle r_0, r_0 \rangle$. ✓

Caso $k \geq 1$: $u_k = r_k - \beta_{k-1} u_{k-1}$, luego $\langle u_k, r_k \rangle = \langle r_k, r_k \rangle - \beta_{k-1} \underbrace{\langle u_{k-1}, r_k \rangle}_{=0} = \langle r_k, r_k \rangle$, donde

$\langle u_{k-1}, r_k \rangle = 0$ porque t_{k-1} minimiza la función cuadrática a lo largo de u_{k-1} , lo que implica que $r_k \perp u_{k-1}$. Sustituyendo en $t_k = \langle u_k, r_k \rangle / \langle u_k, Au_k \rangle$: □ □

$\beta_k = -\langle r_{k+1}, r_{k+1} \rangle / \langle r_k, r_k \rangle$. De $r_{k+1} = r_k - t_k Au_k$ se despeja $Au_k = (r_k - r_{k+1}) / t_k$. Entonces:

$$\langle r_{k+1}, Au_k \rangle = \frac{1}{t_k} \left(\underbrace{\langle r_{k+1}, r_k \rangle}_{=0} - \langle r_{k+1}, r_{k+1} \rangle \right) = -\frac{\langle r_{k+1}, r_{k+1} \rangle}{t_k}.$$

Por tanto: $\beta_k = \frac{-\langle r_{k+1}, r_{k+1} \rangle / t_k}{\langle u_k, Au_k \rangle} = -\frac{\langle r_{k+1}, r_{k+1} \rangle}{t_k \langle u_k, Au_k \rangle} = -\frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle}$, usando $t_k \langle u_k, Au_k \rangle = \langle r_k, r_k \rangle$. □ □

15. Demostraciones adicionales (cont.)

15.1. Unicidad de la factorización de Cholesky

Demostración. Suponga $A = LL^T = MM^T$ con L, M triangulares inferiores y $\ell_{ii}, m_{ii} > 0$.

Sea $R = M^{-1}L$ (triangular inferior). De $LL^T = MM^T$:

$$M^{-1}(LL^T)M^{-T} = I \Rightarrow (M^{-1}L)(M^{-1}L)^T = I \Rightarrow RR^T = I.$$

R es ortogonal y triangular inferior. Mostramos que $R = I$ por inducción:

Fila 1: $(RR^T)_{11} = r_{11}^2 = 1$ y $r_{11} = \ell_{11}/m_{11} > 0$, luego $r_{11} = 1$. Para $i > 1$: $(RR^T)_{i1} = r_{i1} \cdot r_{11} = r_{i1} = 0$.

Fila j (inductivo): Suponiendo $r_{sk} = \delta_{sk}$ para $s, k < j$: $(RR^T)_{jj} = r_{jj}^2 = 1$ con $r_{jj} > 0$, luego $r_{jj} = 1$. Para $i > j$: $(RR^T)_{ij} = r_{ij} \cdot r_{jj} = r_{ij} = 0$.

Por tanto $R = I$, es decir $M^{-1}L = I$, luego $L = M$. □ □